IA para la Industria: detectar problemas de manufacturing

Industriarako Adimen Artifiziala: manufacturing arazoak detektatzea

28/10/2020 – 16/12/2020

Sobre mi

@IKERLANofficial

Mikel Cañizo Zubizarreta

Investigador del equipo de **Data Analytics e Inteligencia Artificial** en

Mantenimiento Predictivo

Analítica Avanzada

Monitorización en Tiempo Real

Plataformas Digitales

Deep Learning

Sobre mi

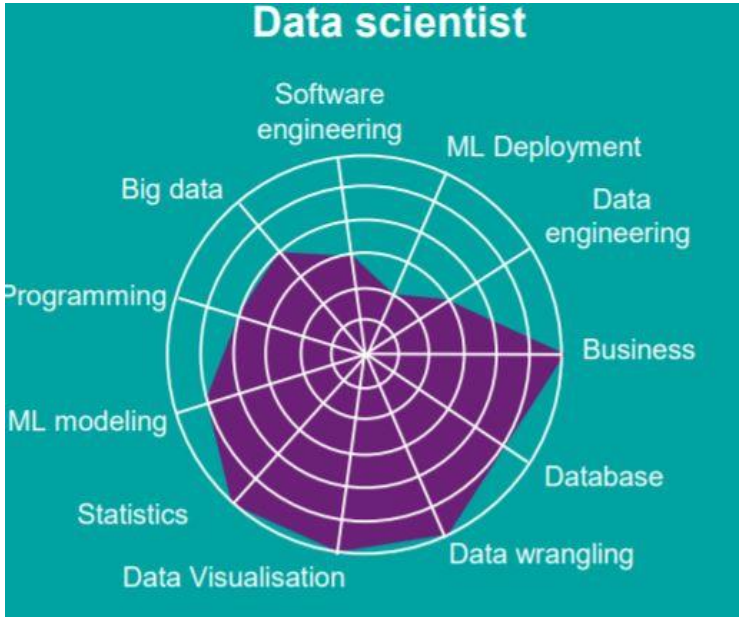

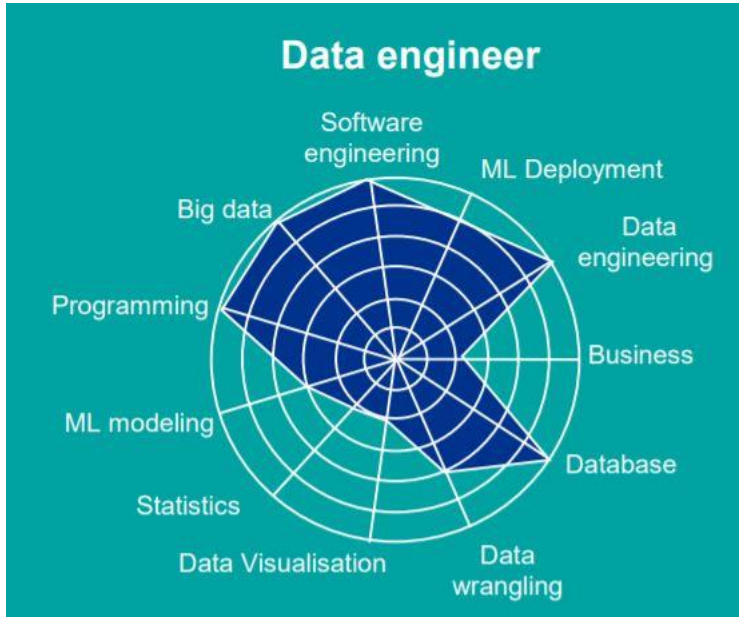

Híbrido entre **científico de datos** e **ingeniero de datos**

Lo aprendido durante el curso

- **Plataformas digitales:**
  - *Herramientas y servicios para el envío, procesamiento y almacenamiento de los datos*
  - *Big Data*

Lo aprendido durante el curso

- **Plataformas digitales:**
  - *Herramientas y servicios para el envío, procesamiento y almacenamiento de los datos*
  - *Big Data*
- **Preprocesado:**
  - Procesado de los datos crudos
  - Preparación de los datos para generar modelos IA

Lo aprendido durante el curso

- **Plataformas digitales:**
  - *Herramientas y servicios para el envío, procesamiento y almacenamiento de los datos*
  - *Big Data*
- **Preprocesado:**
  - Procesado de los datos crudos
  - Preparación de los datos para generar modelos IA
- **Visualización:**
  - Visualización de los datos
  - ¿Qué forma tienen los datos?

Lo aprendido durante el curso

- **Plataformas digitales:**
  - *Herramientas y servicios para el envío, procesamiento y almacenamiento de los datos*
  - *Big Data*
- **Preprocesado:**
  - Procesado de los datos crudos
  - Preparación de los datos para generar modelos IA
- **Visualización:**
  - Visualización de los datos
  - ¿Qué forma tienen los datos?
- **Análisis y validación:**
  - Tipos de modelos de IA
  - Generación de modelos (detección de anomalías)

Lo aprendido durante el curso

- **Plataformas digitales:**
  - *Herramientas y servicios para el envío, procesamiento y almacenamiento de los datos*
  - *Big Data*
- **Preprocesado:**
  - Procesado de los datos crudos
  - Preparación de los datos para generar modelos IA
- **Visualización:**
  - Visualización de los datos
  - ¿Qué forma tienen los datos?
- **Análisis y validación:**
  - Tipos de modelos de IA
  - Generación de modelos (detección de anomalías)
- **¿¿Despliegue??**

Qué es el despliegue?

Qué es el despliegue?

Qué es el despliegue?

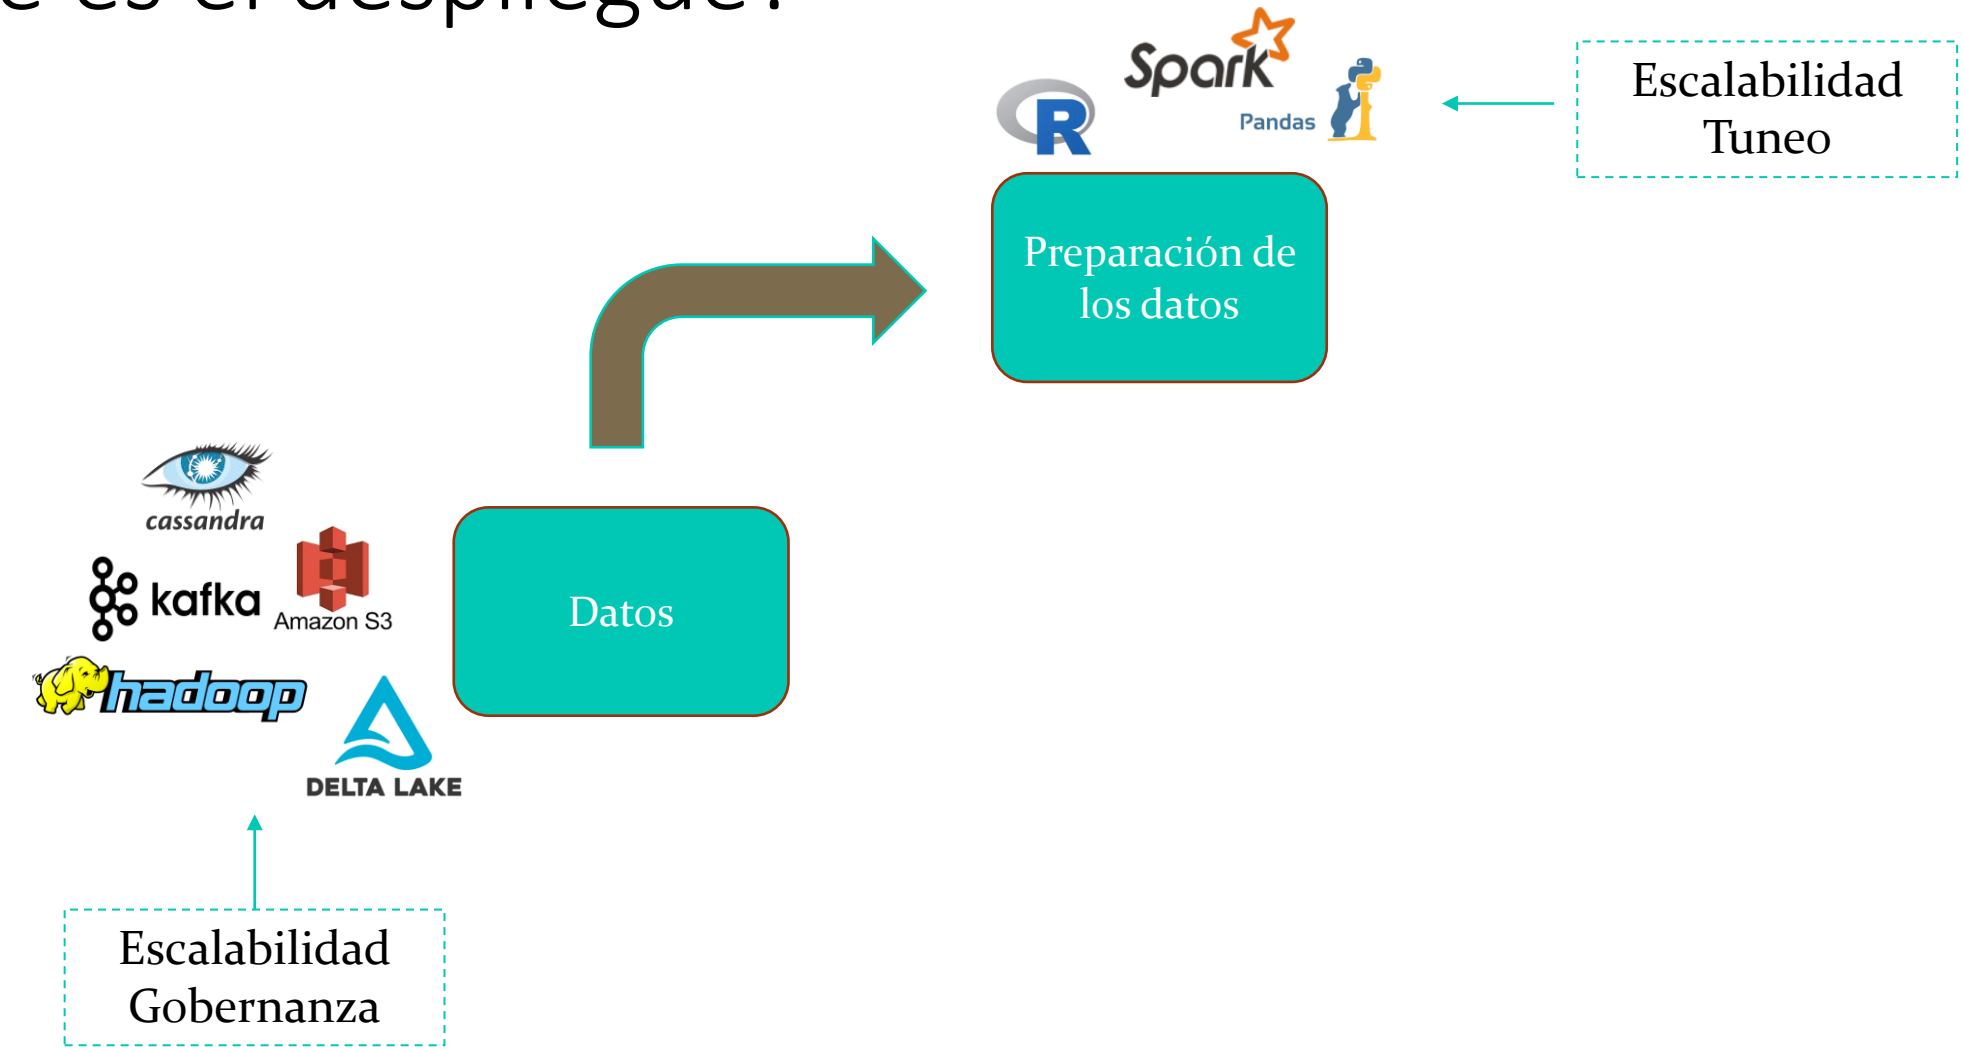

Qué es el despliegue?

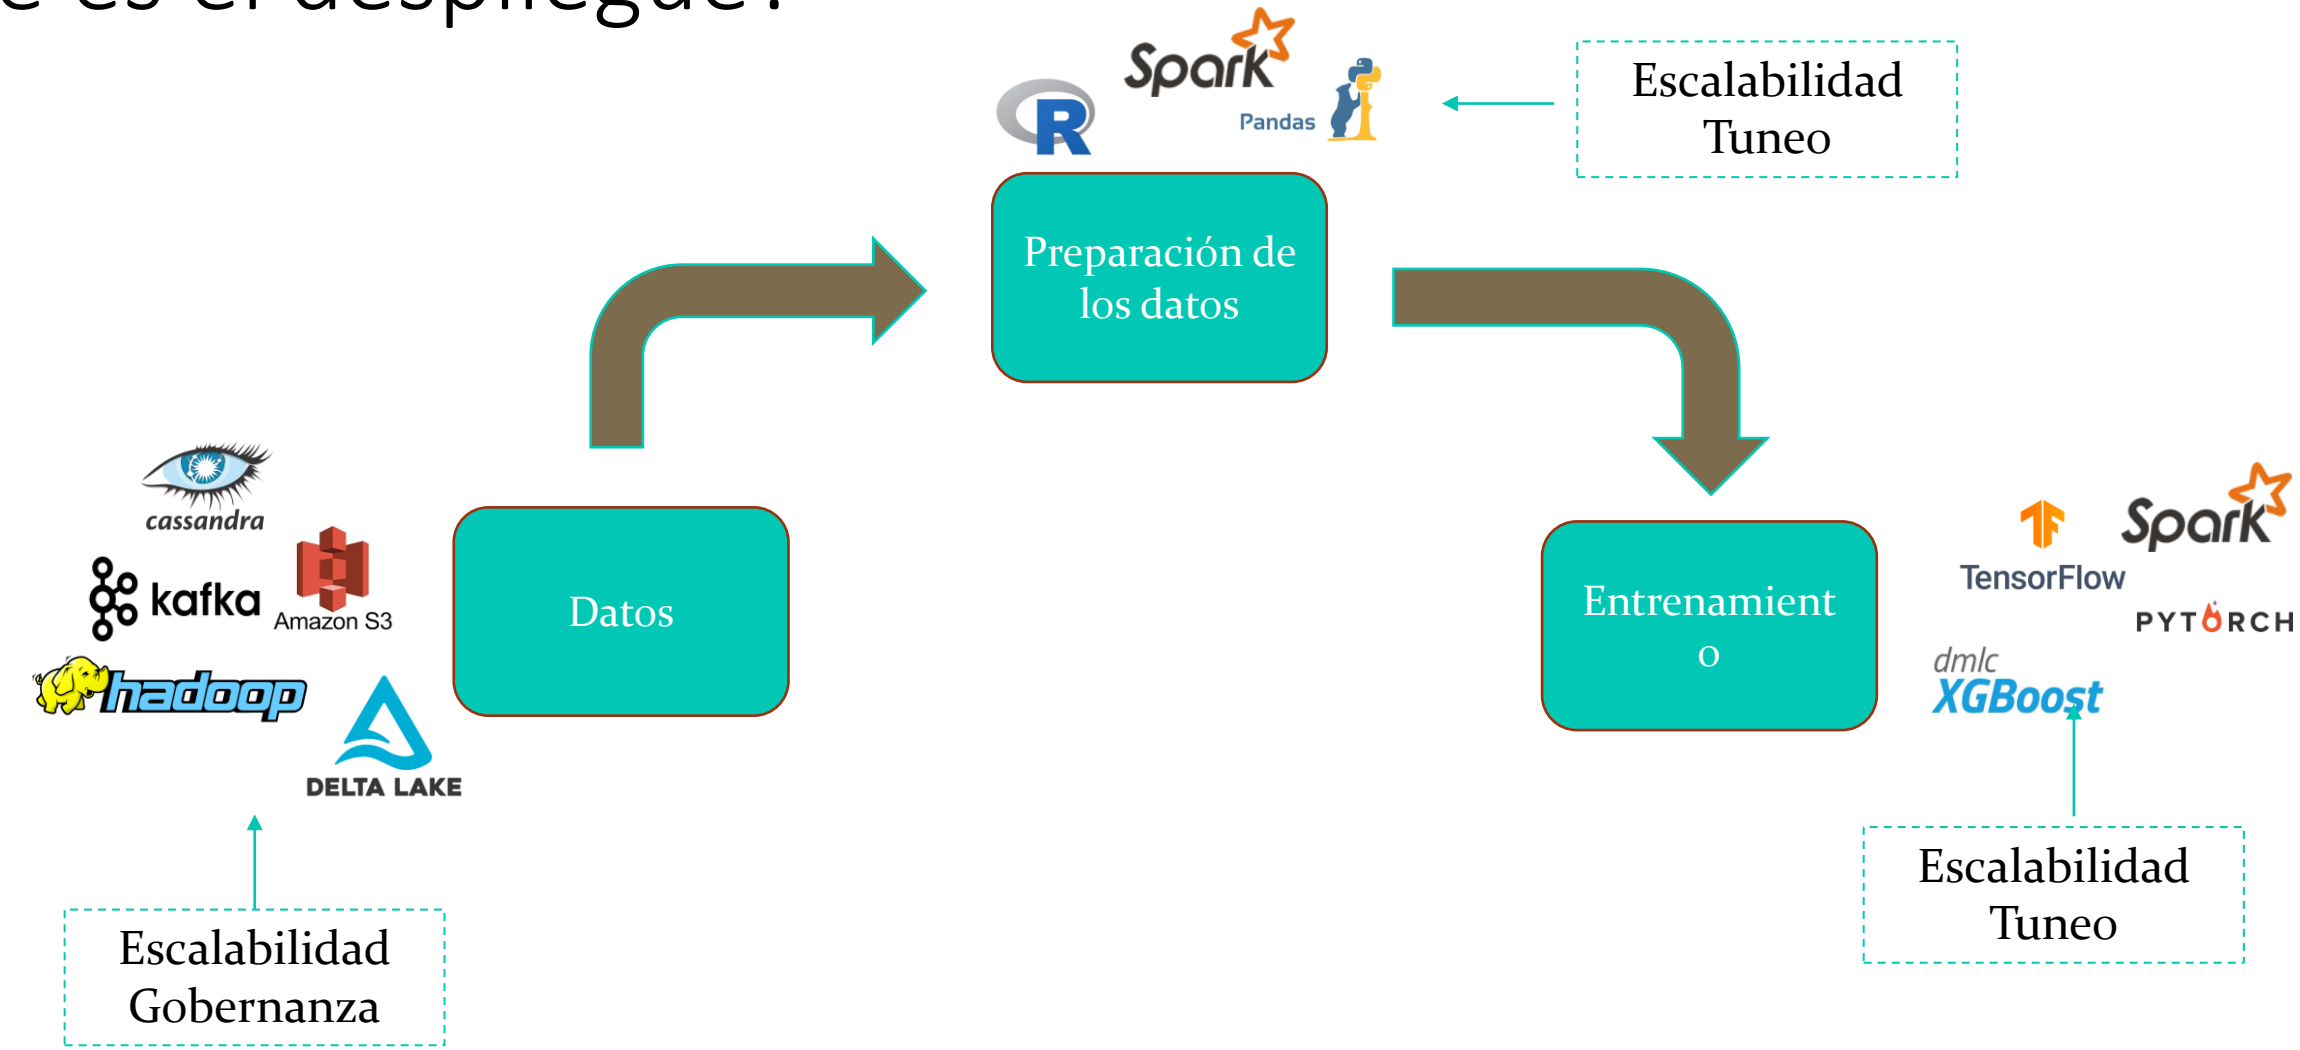

Qué es el despliegue?

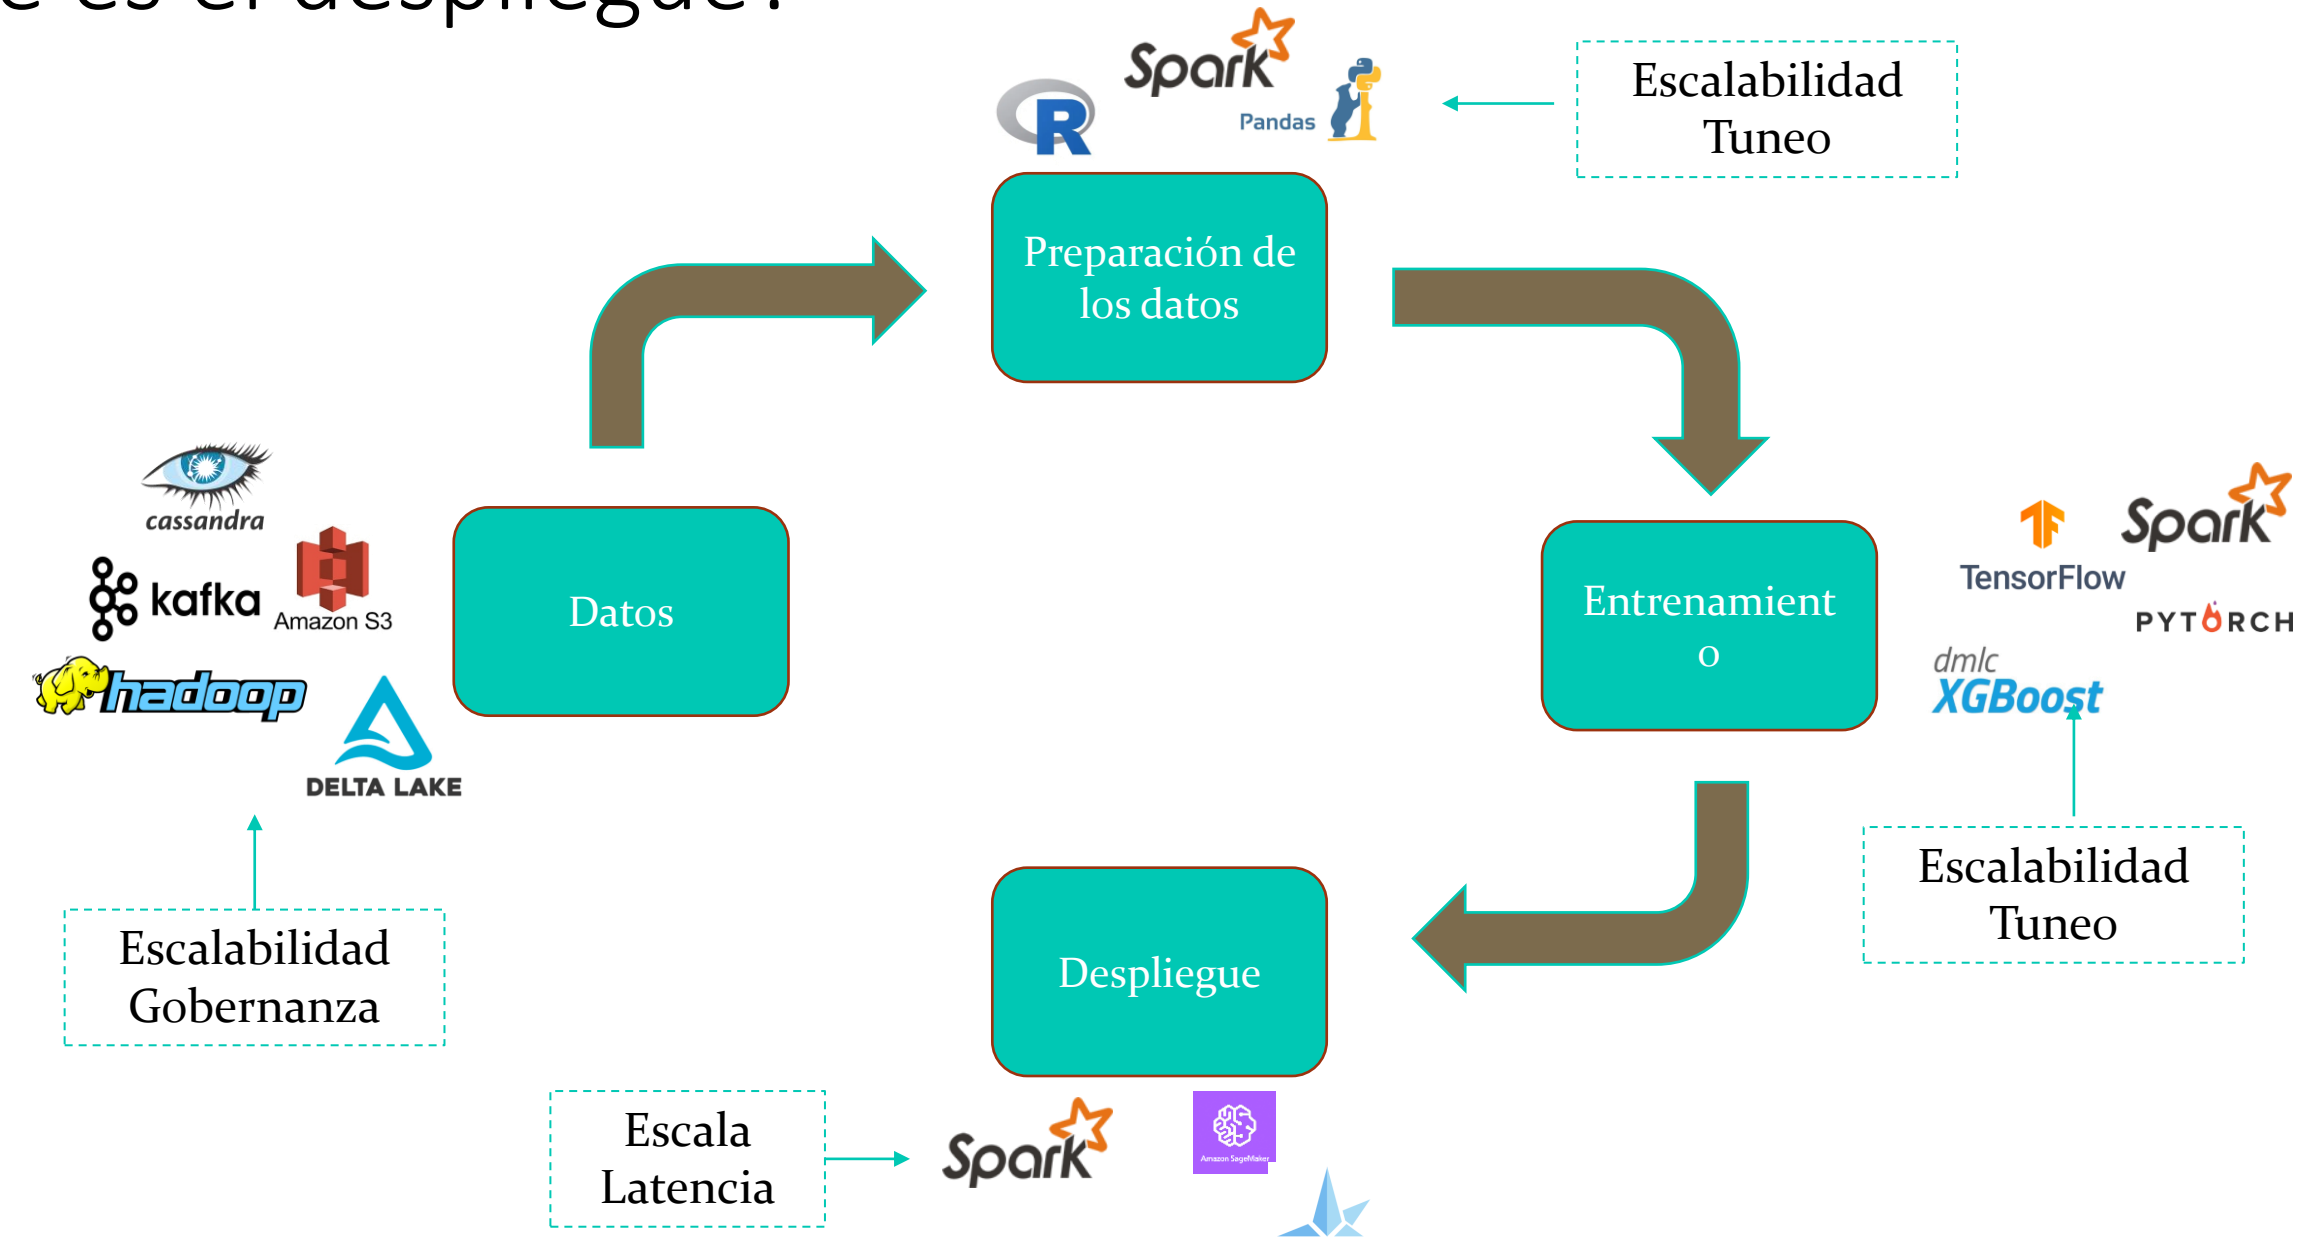

Qué es el despliegue?

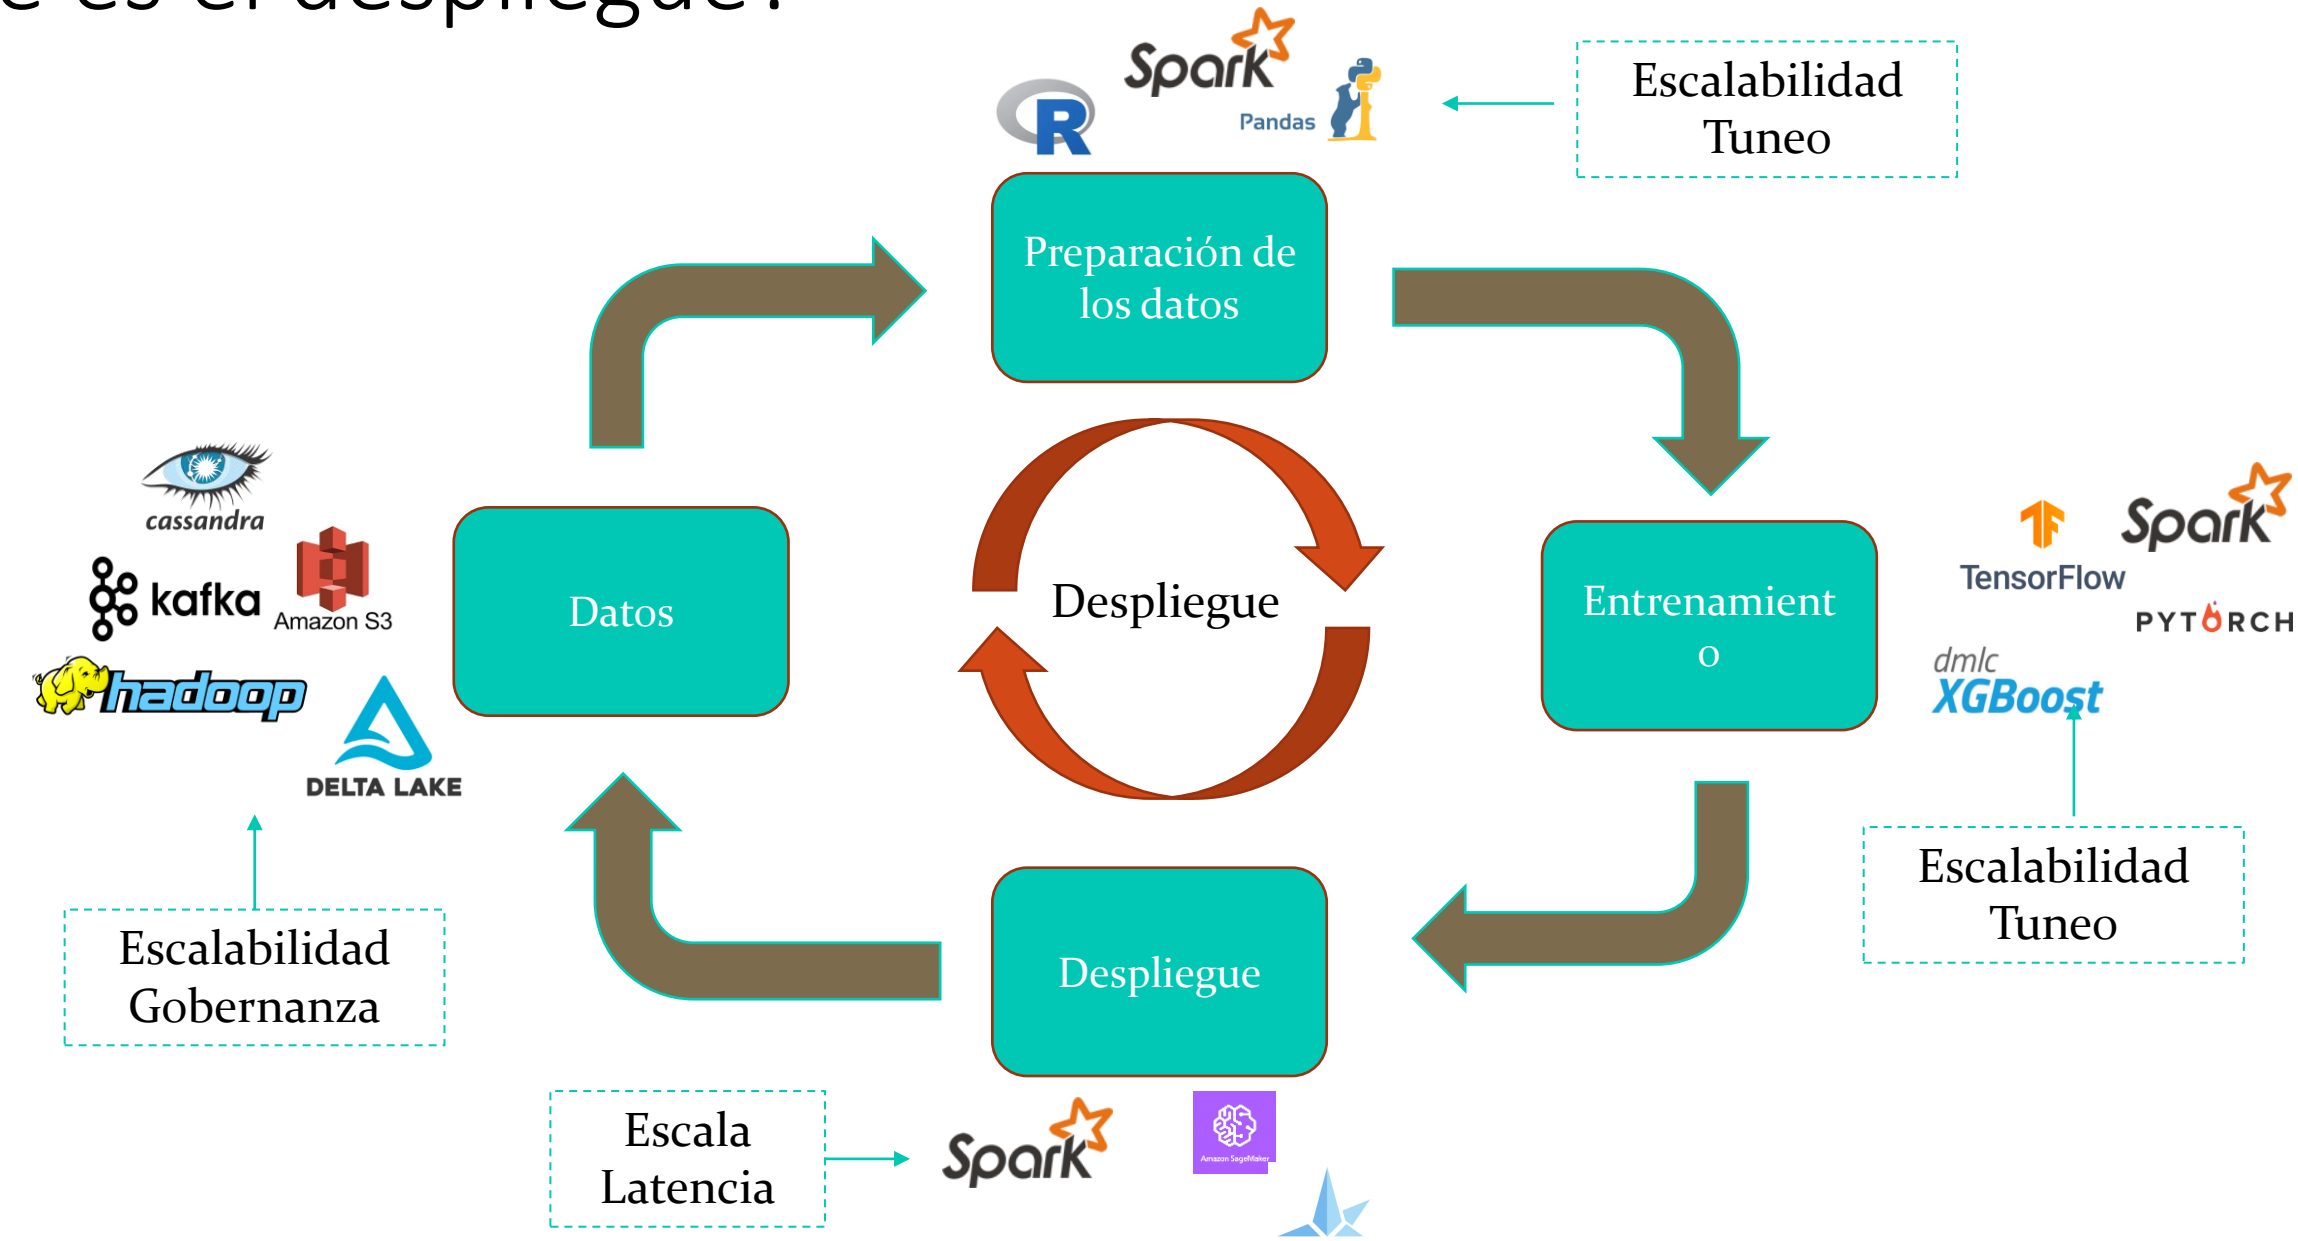

Despliegue de modelos

- ¿Es la **realidad** así de simple?

La realidad

- ¿**Qué versión** del modelo desplegamos?
  - Preprocesamientos diferentes
  - Feature engineering
  - Hyperparameter tuning
  - Versiones de los datos

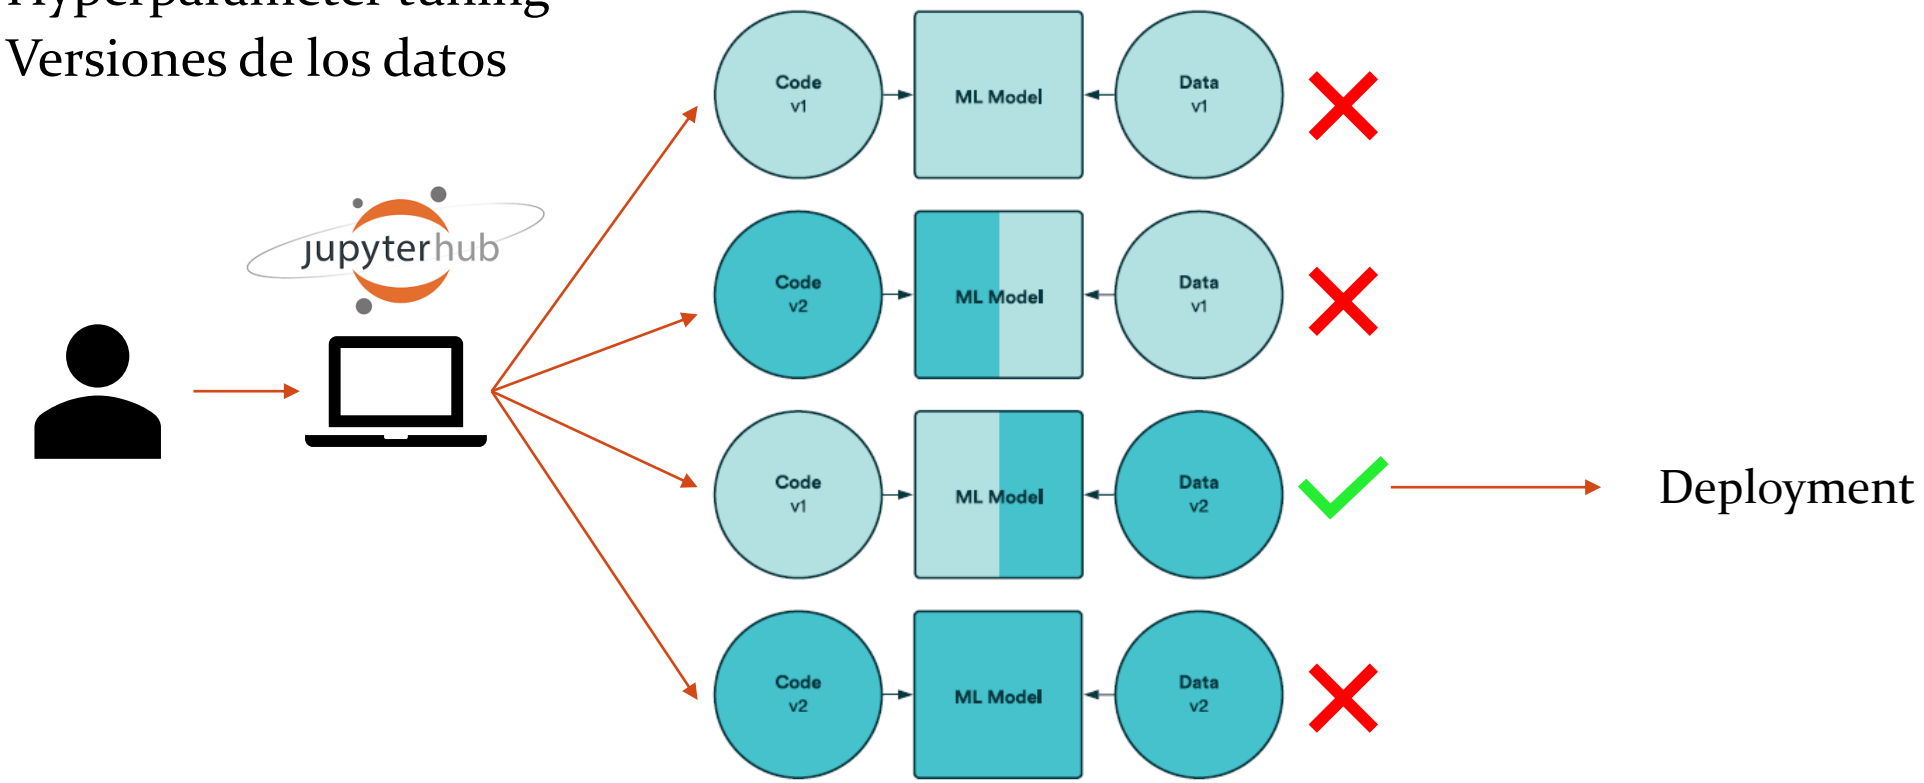

La realidad

- ¿ **Dónde** despliego el modelo?

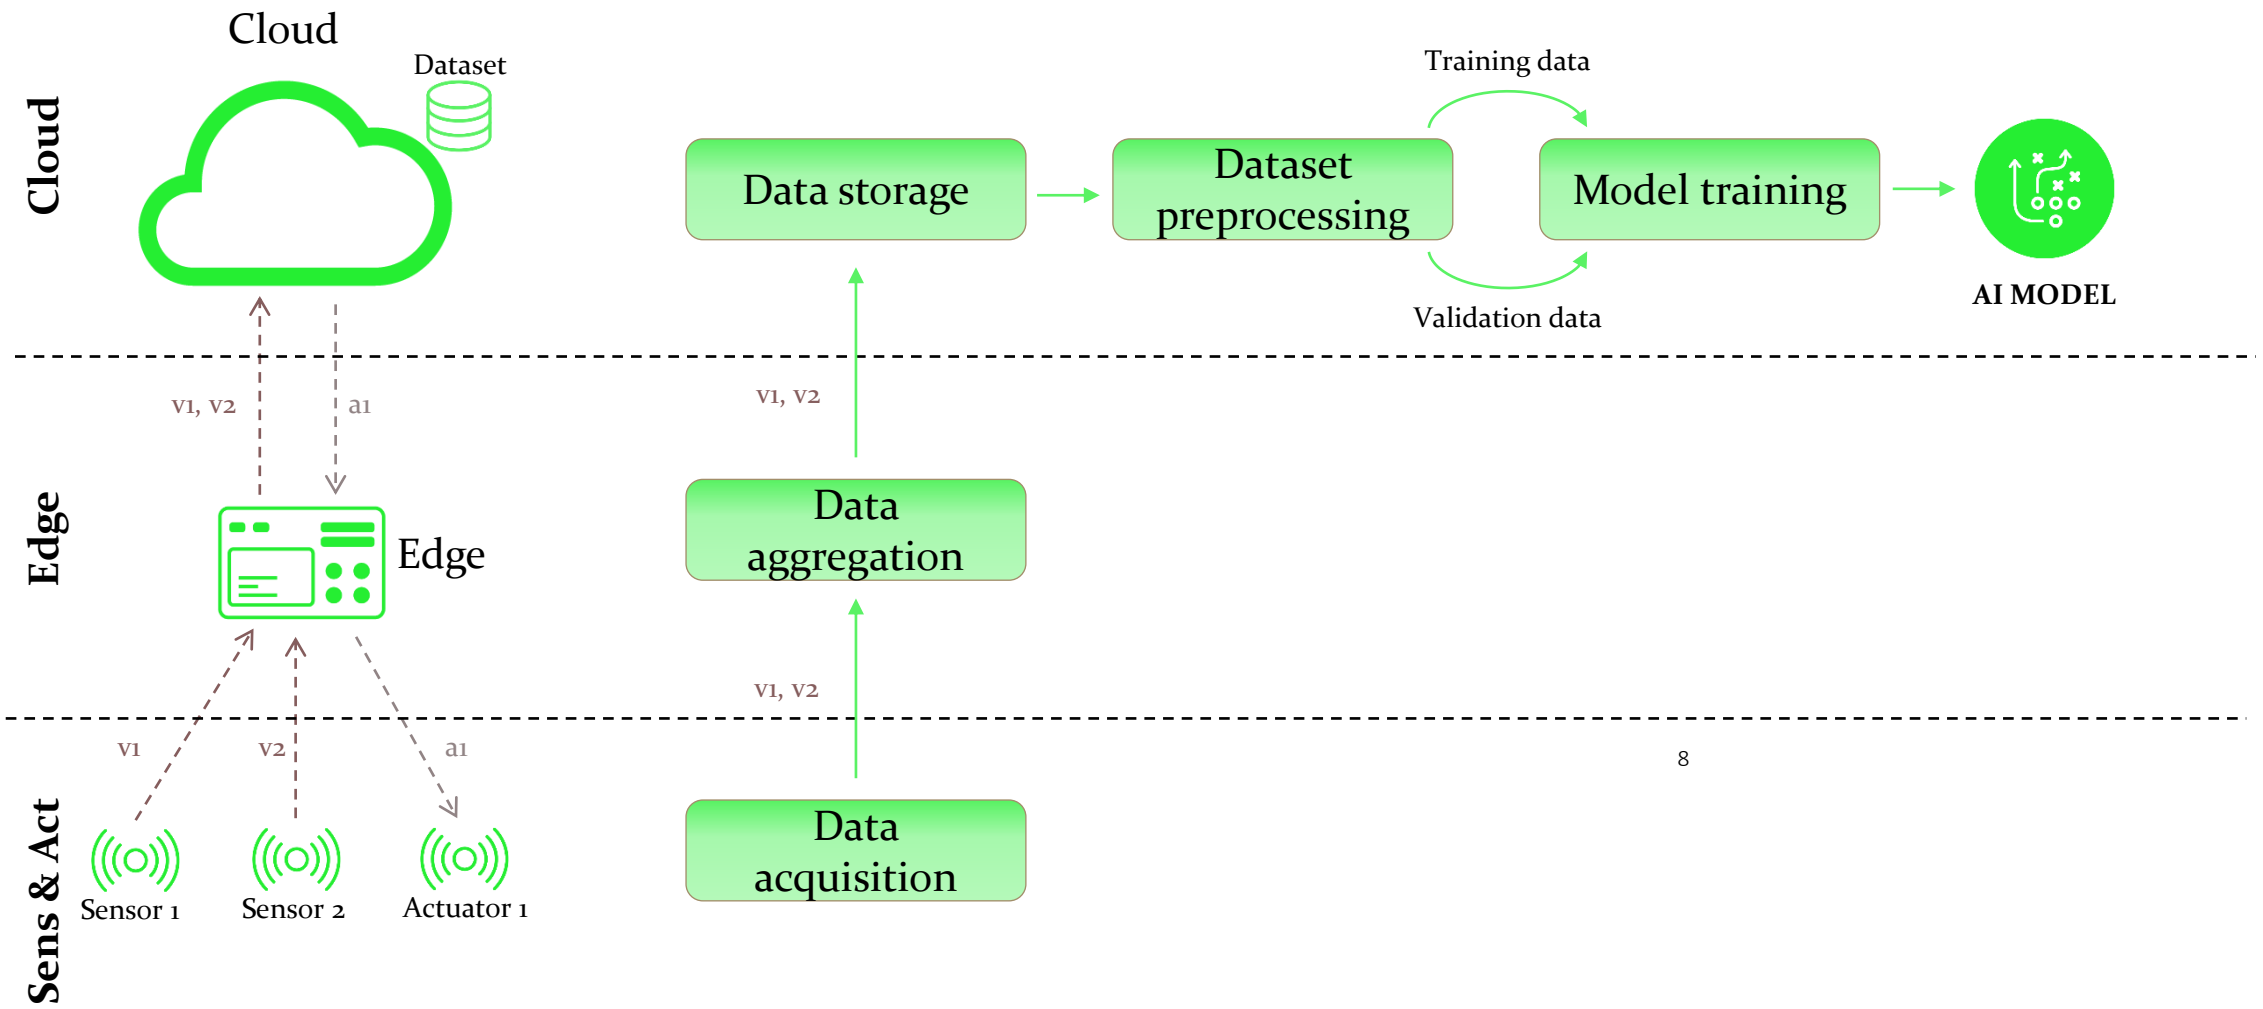

La realidad

- ¿ **Dónde** despliego el modelo?

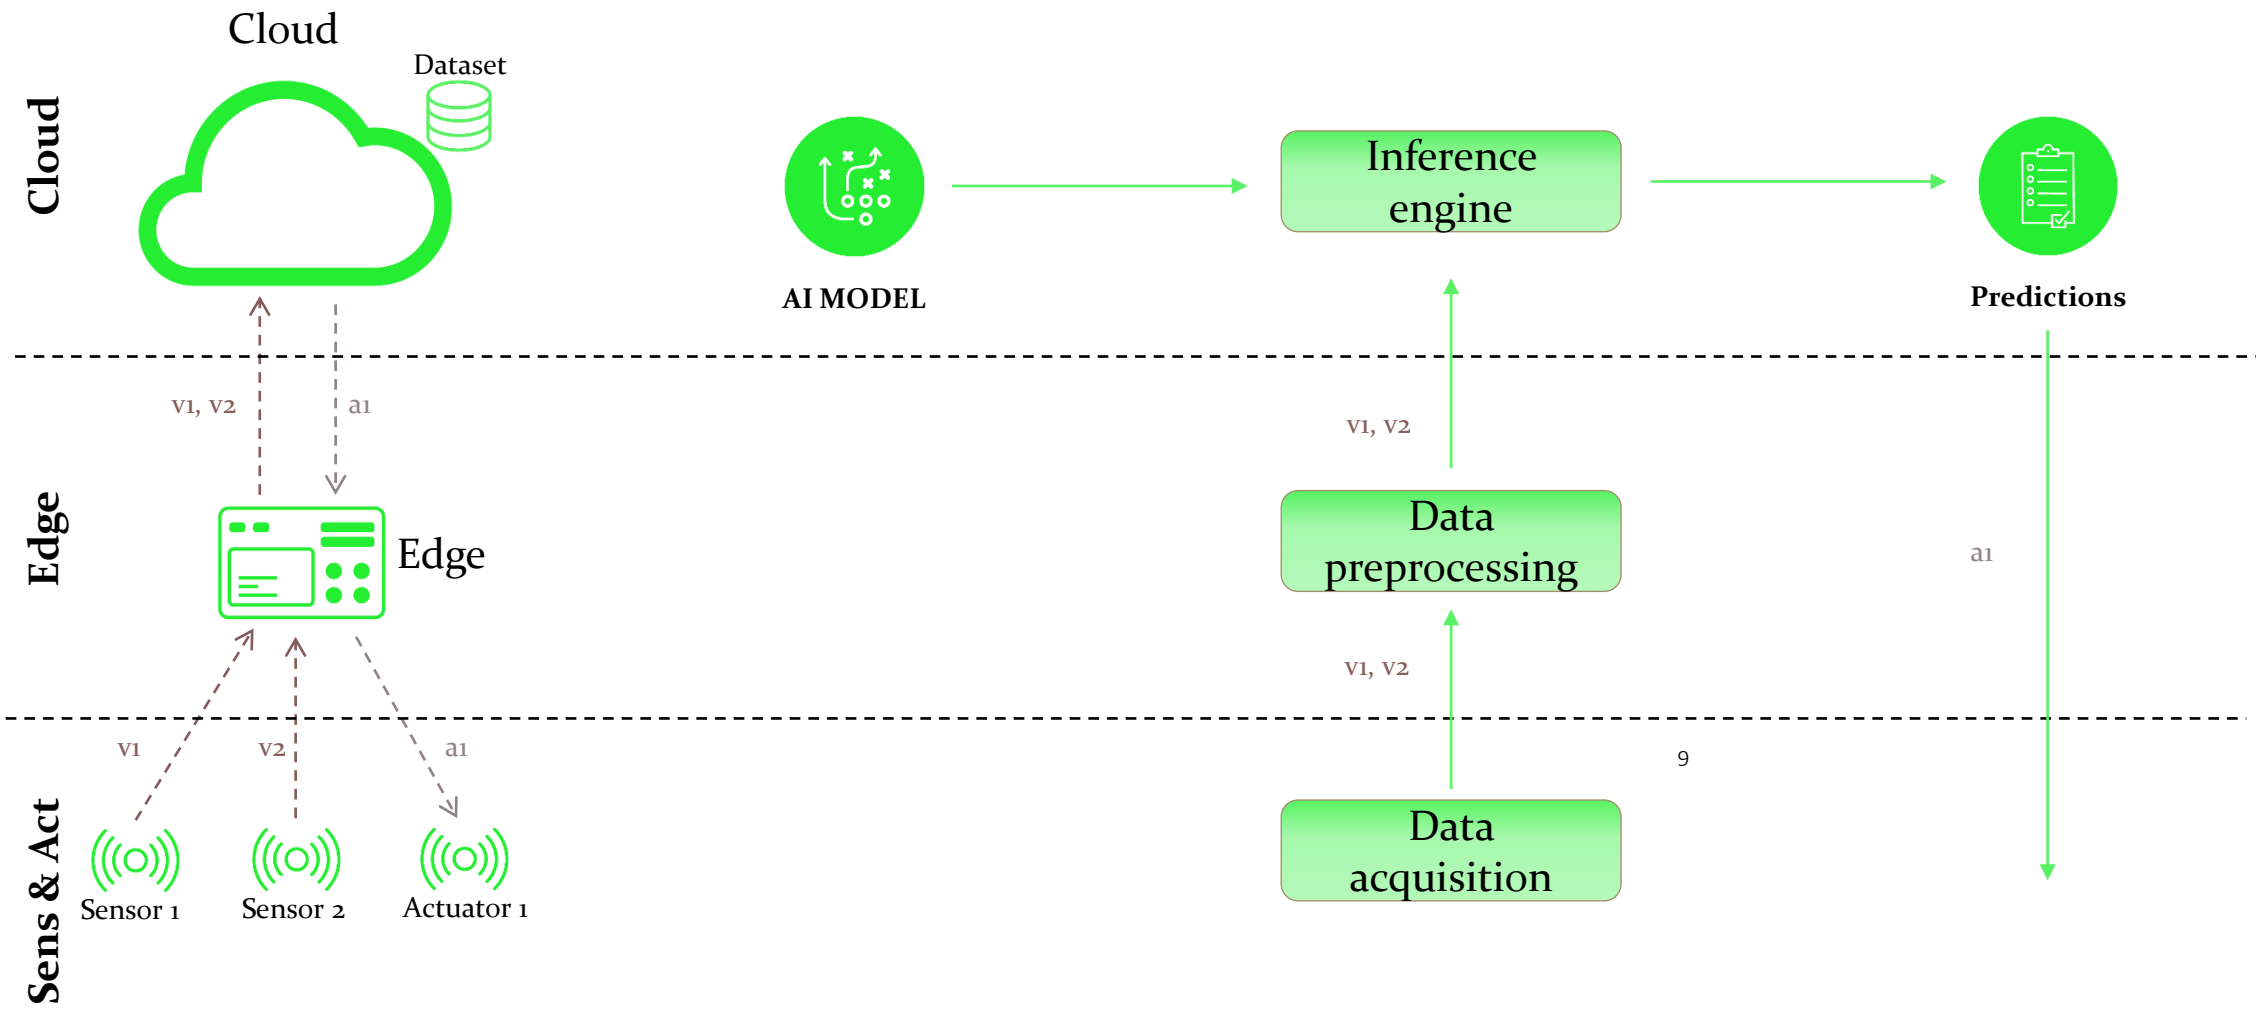

La realidad

- ¿ **Dónde** despliego el modelo?

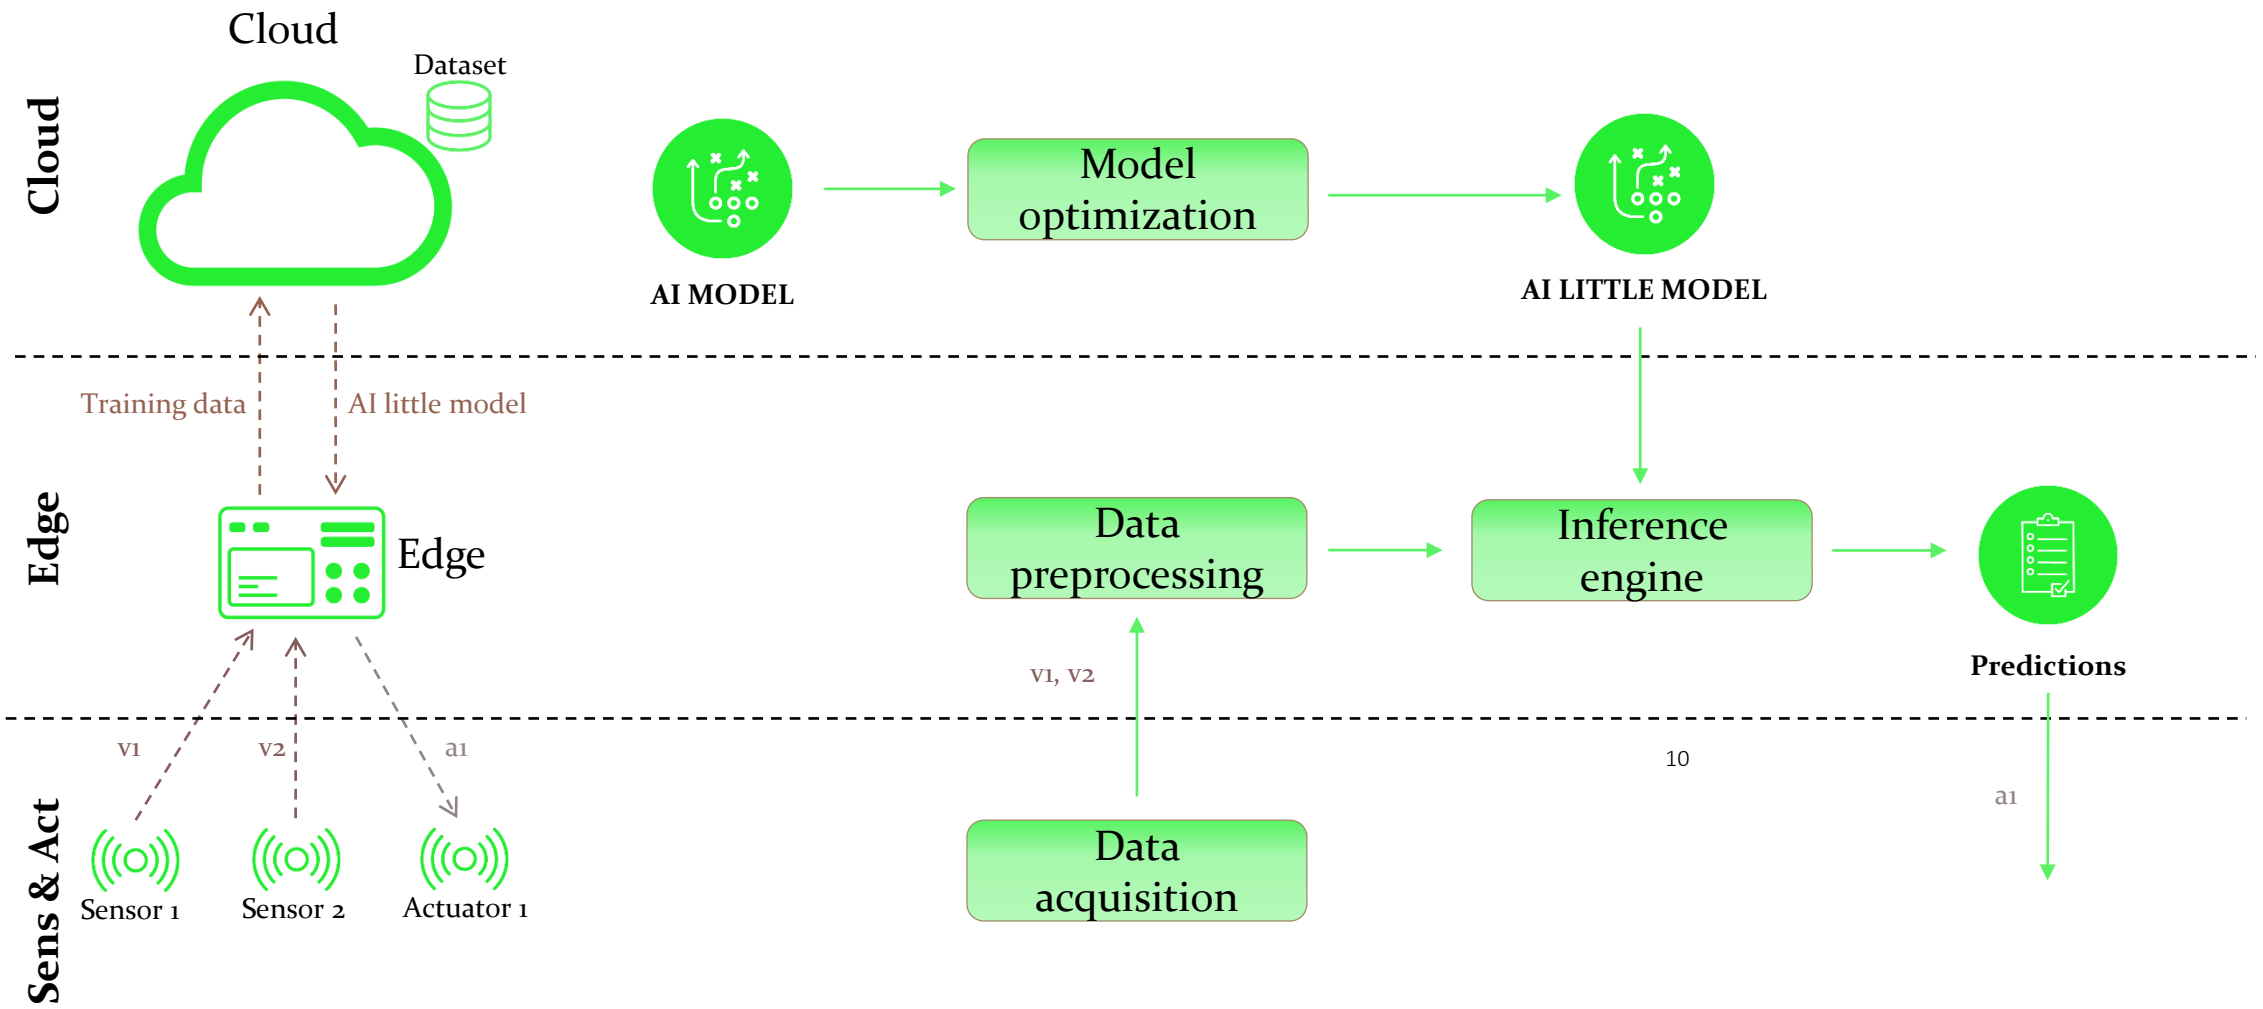

La realidad

- ¿ **Dónde** despliego el modelo?

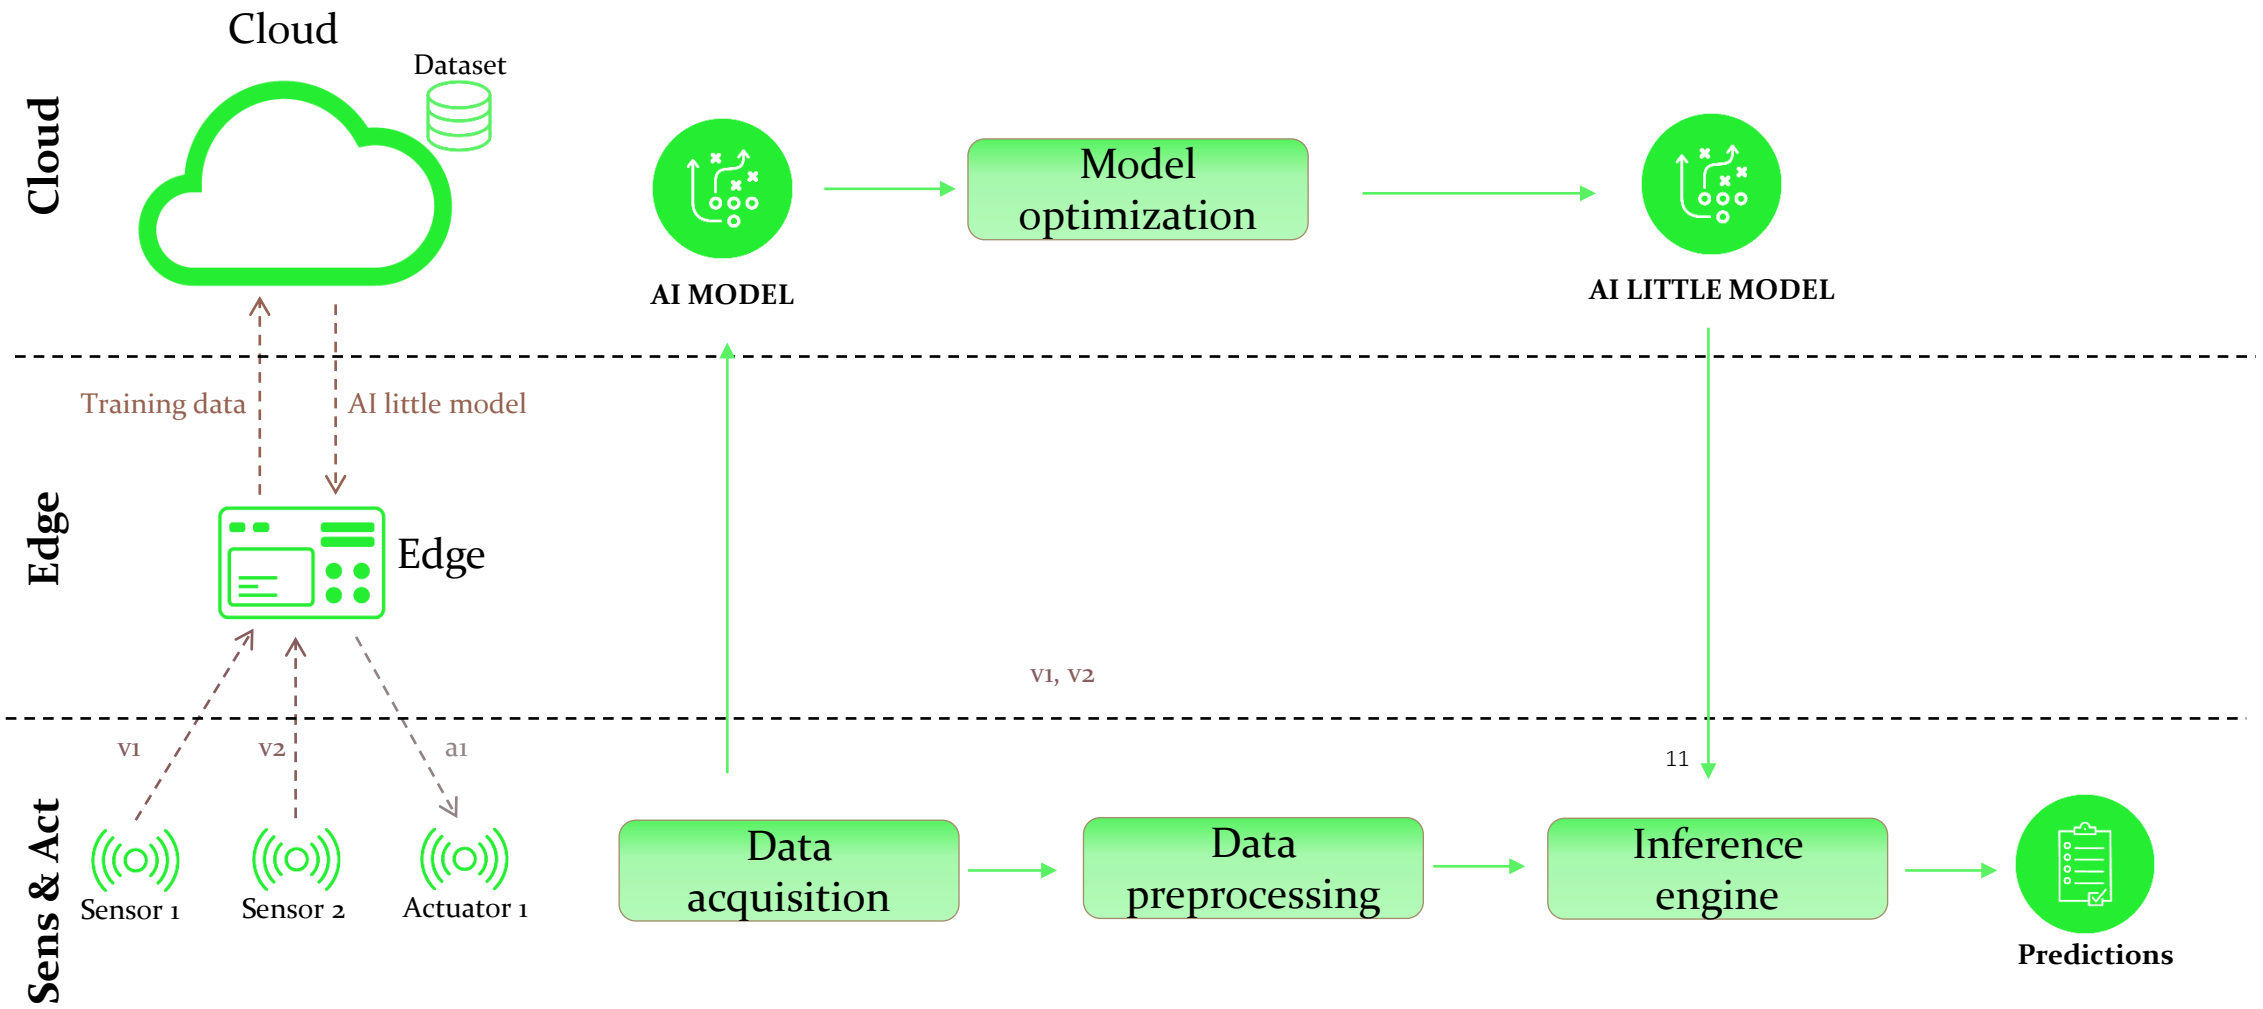

La realidad

- ¿**En qué formato** desplegamos el modelo?
  - No todas las herramientas usan los mismos formatos
  - Diferentes herramientas de entrenamiento y producción
  - Limitaciones de memoria (embebidos, móviles…)

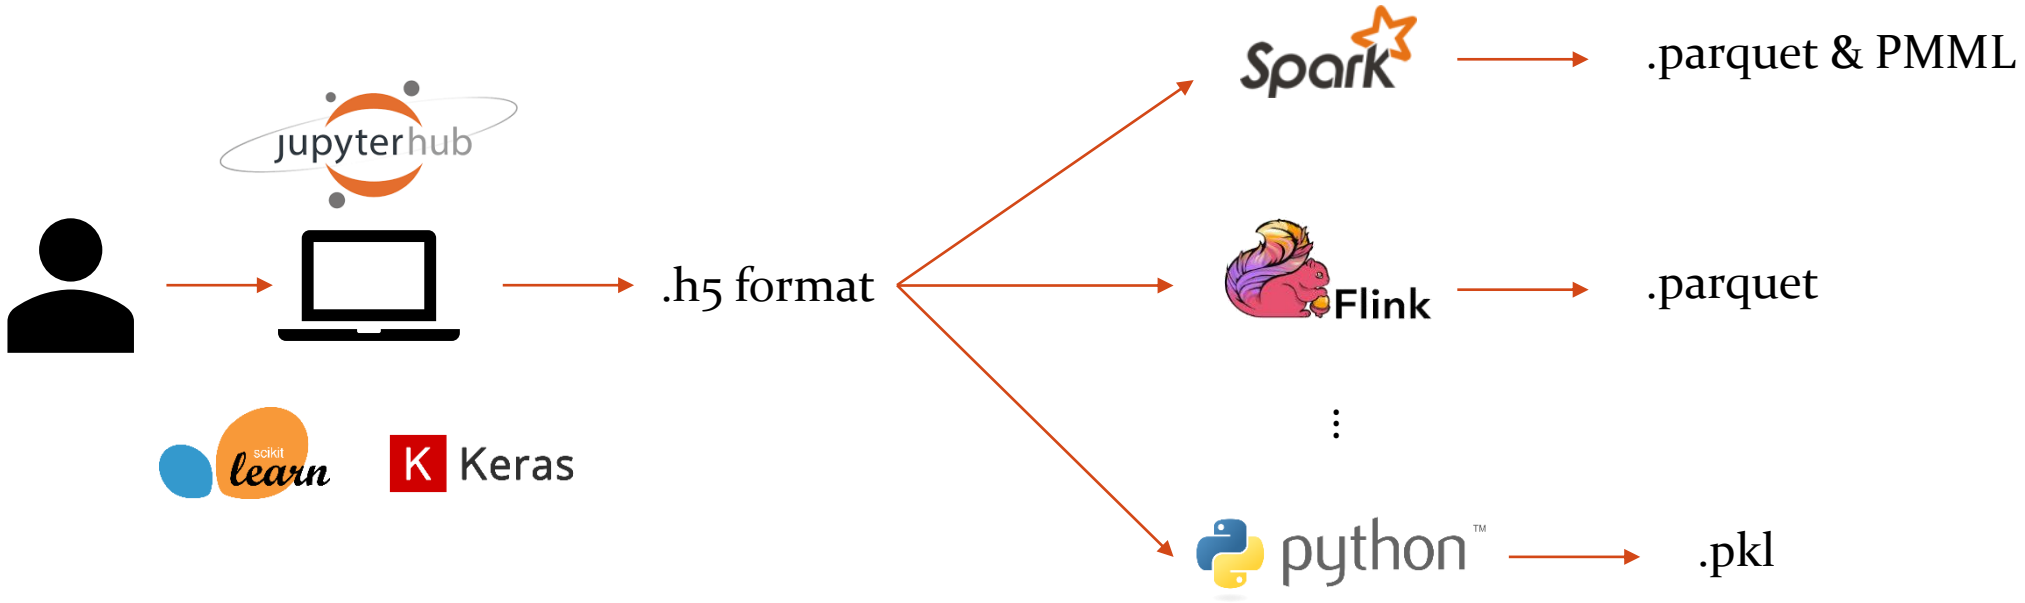

La realidad

- ¿**Cuándo** despliego el nuevo modelo?
  - **Evolución de los sistemas** monitorizados
  - **Monitorización** de los modelos
  - **Concept drift**
  - ¿Cúando **re-entrenar** el modelo?

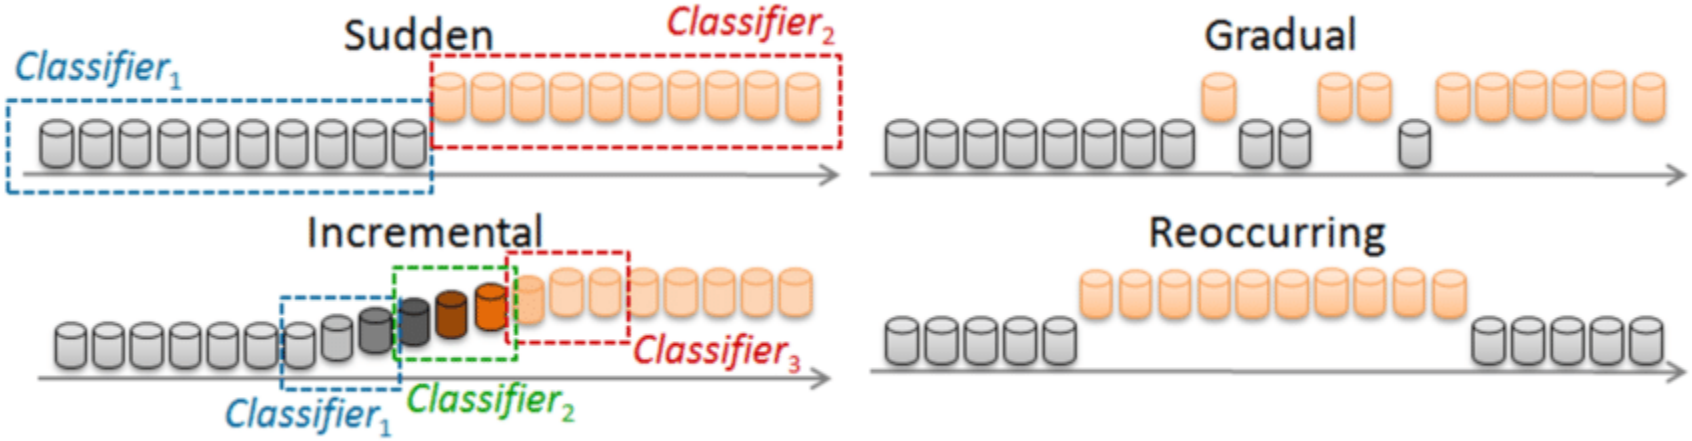

La realidad

- ¿Cómo llevo la **trazabilidad** del modelo?
  - **Múltiples versiones** de los modelos (hiperparámetros, datos…)
  - **¿Cómo saber qué pruebas** he realizado?
  - **¿Cómo volver a atrás** en caso de fallos?
  - **Versiones** de los datos

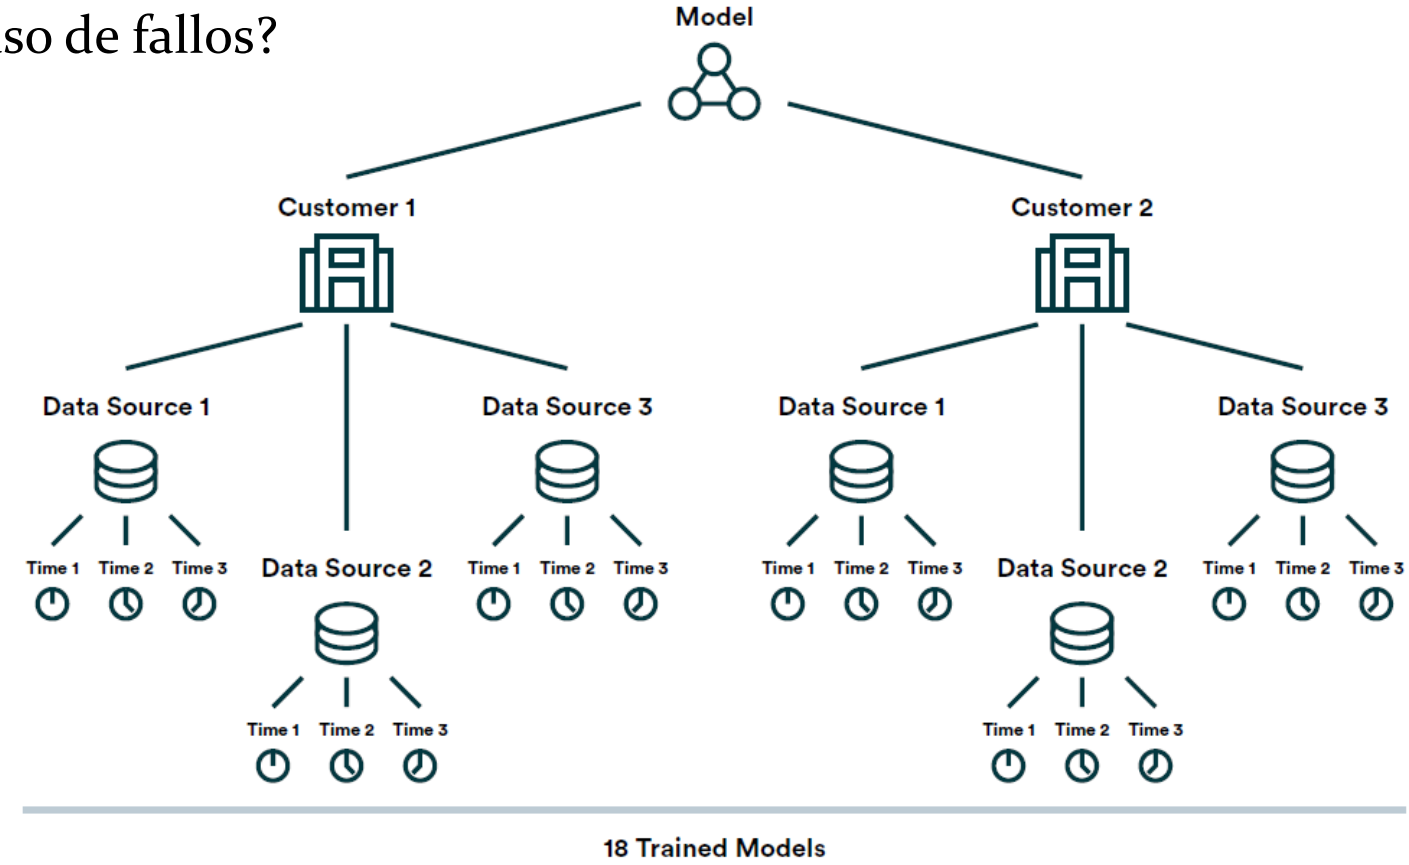

La realidad

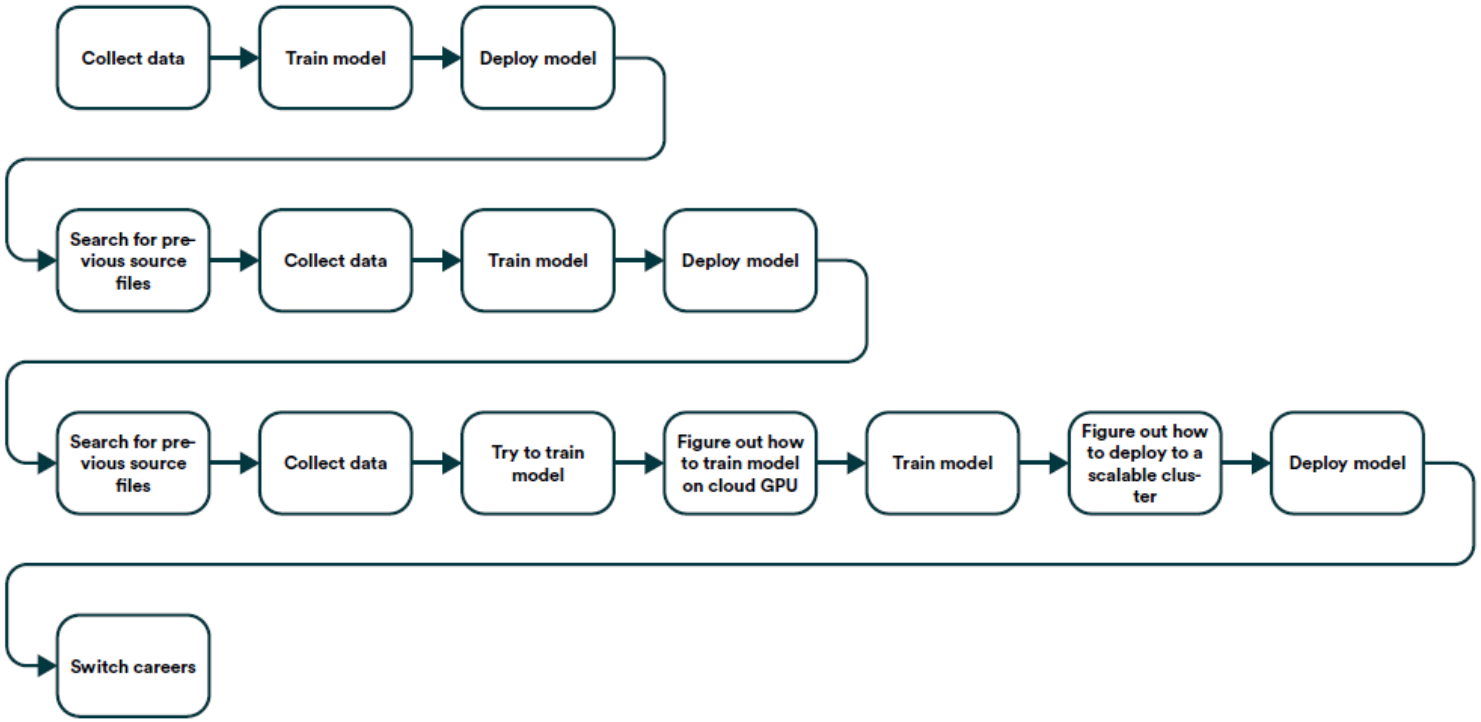

- ¿Cómo llevar a producción todo esto?
- ¿Cómo puedo registrar un histórico de modelos, configuraciones y pruebas?
- ¿Cómo pongo en producción los modelos?

La realidad

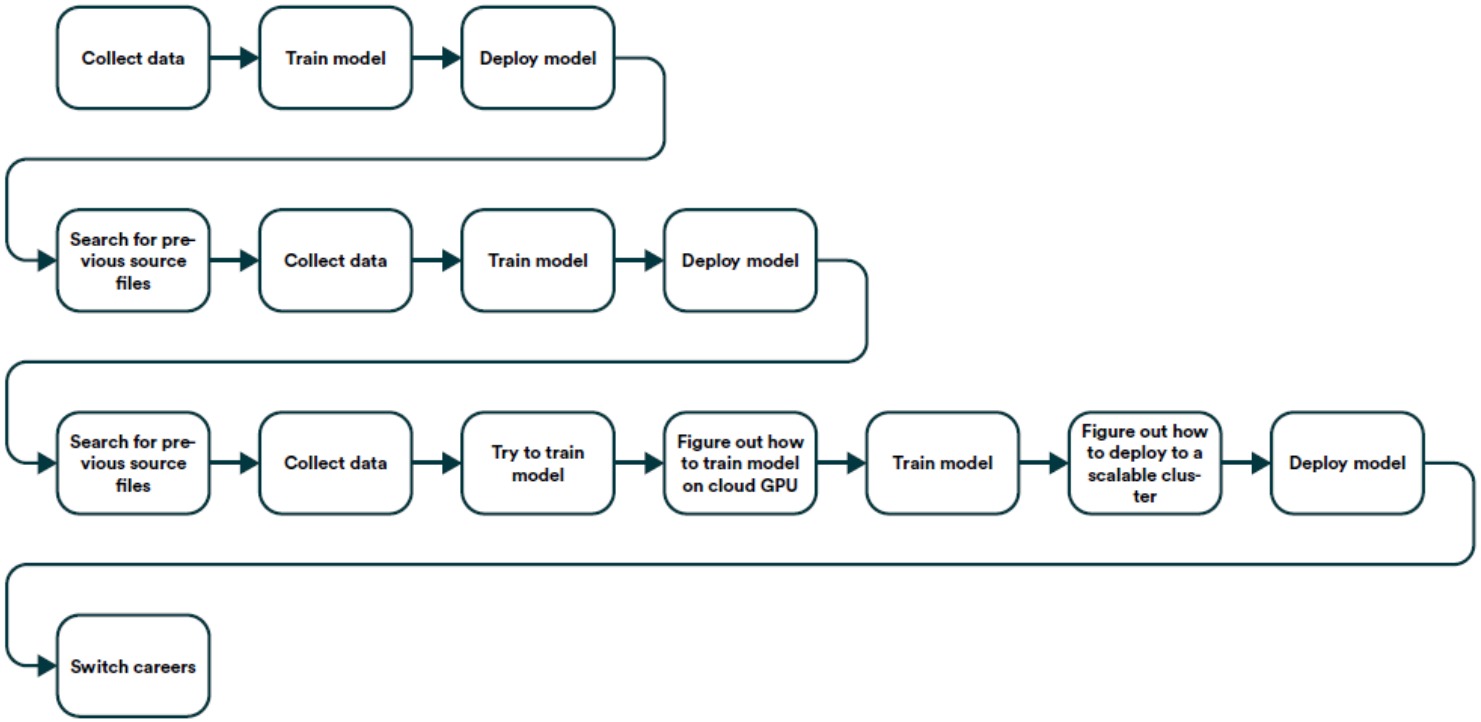

- ¿Cómo llevar a producción todo esto?
- ¿Cómo puedo registrar un histórico de modelos, configuraciones y pruebas?
- ¿Cómo pongo en producción los modelos?

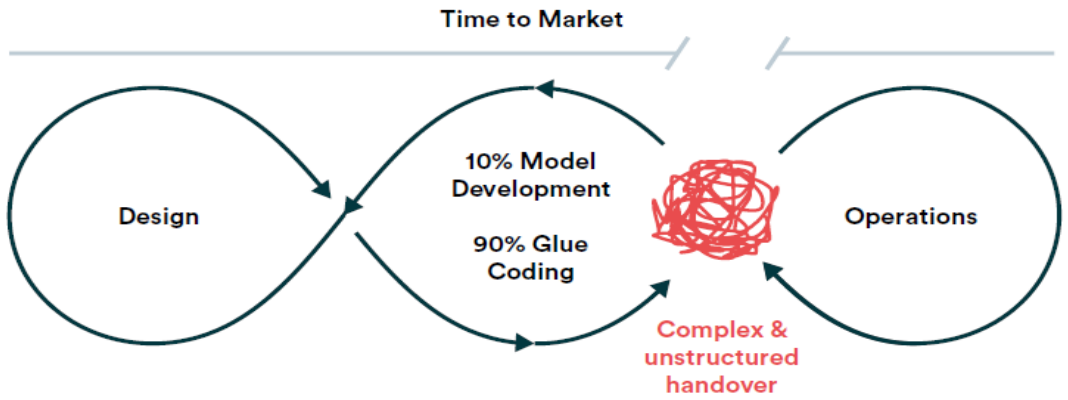

La solución

MLOps = ML + DEV + OPS

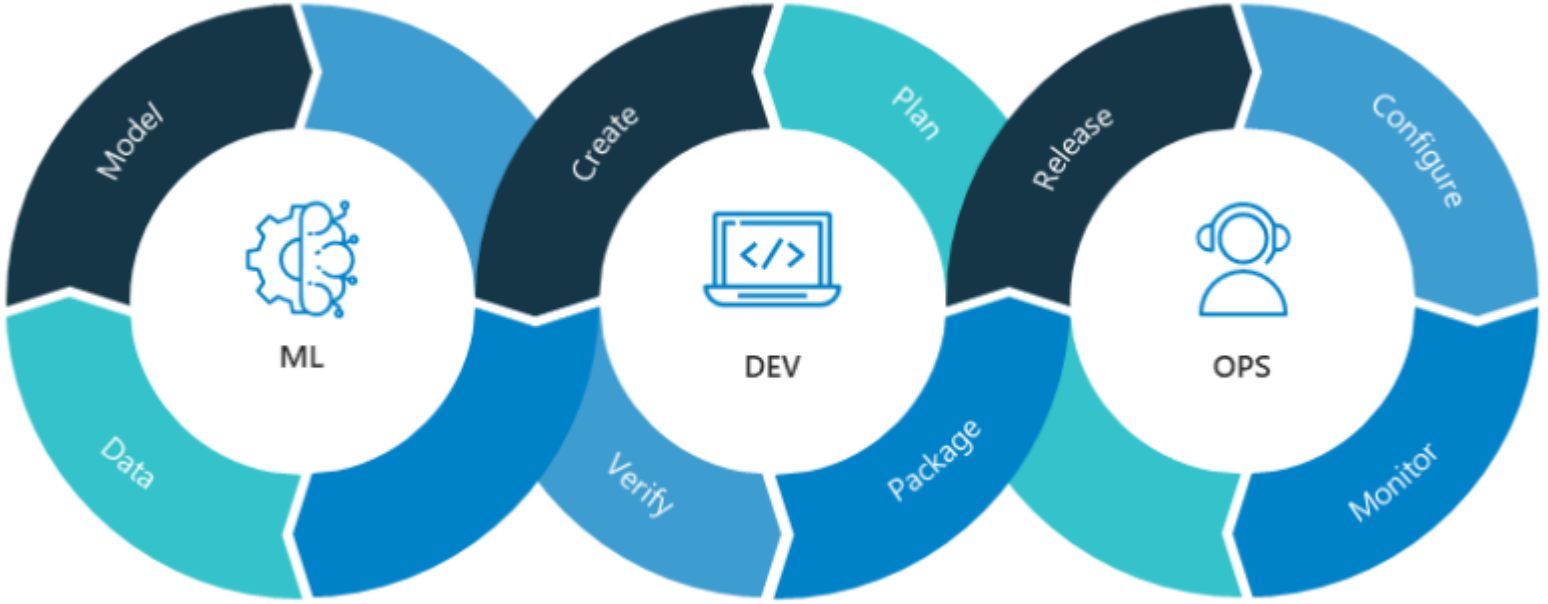

<u>Experiment:</u>
Data acquisition
Business understanding
Initial modeling

<u>Develop:</u>
Modeling + Testing
Continuous integration
Continuous deployment

<u>Operate:</u>
Continuous delivery
Data Feedback Loop
System + Model monitoring

La solución

- Automatización del ciclo de vida de los modelos
  - Seleccionar las herramientas para todo el ciclo de vida
  - Generar pipelines
  - Automatización de toda la fase de desarrollo + validación + despliegue

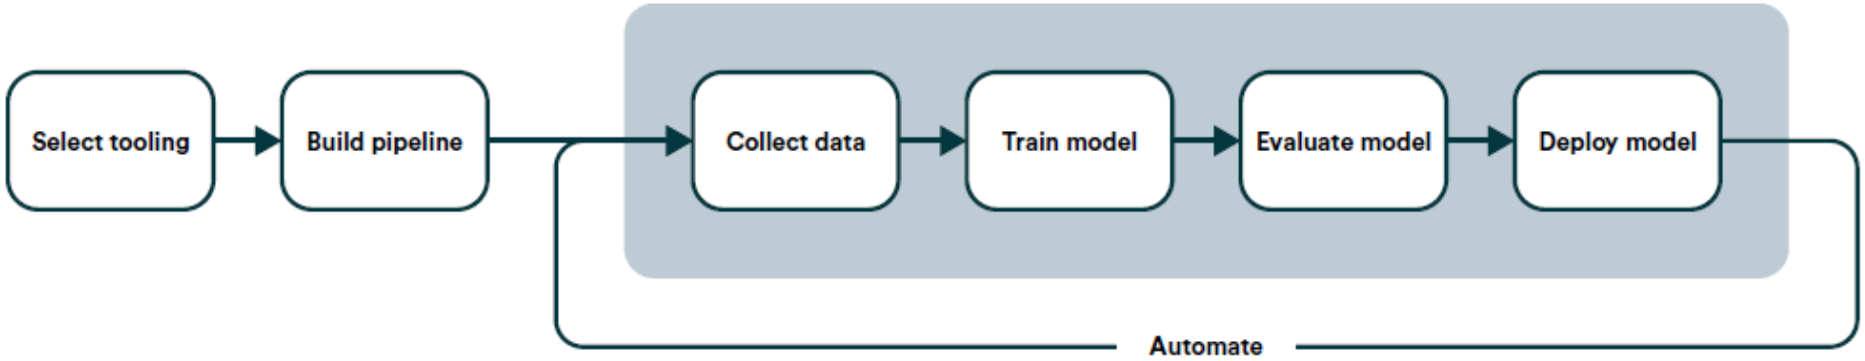

Ventajas

- **Trazabilidad** de los modelos
- **Reproducibilidad**
- **Control del versiones**
- **Conexión** entre Data Scientist y Data Engineer
- Ciclo de vida **automatizado** (menos errores humanos)

Vale, pero…

¿Cómo aplico el **MLOps** al mundo real?

MLOps

- En la actualidad existen varias plataformas

AWS MLOps

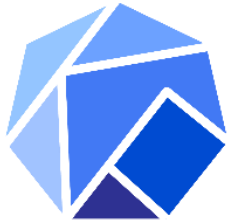

Microsoft Machine Learning for Apache Spark

mlflow

- Es una **plataforma end-to-end** para la **gestión** del **ciclo de vida** de los modelos IA
  - Integración con cualquier librería (scikit-learn, TF, keras, Pytorch, Spark, Flink…)
  - Python, R o JAVA
  - Open source

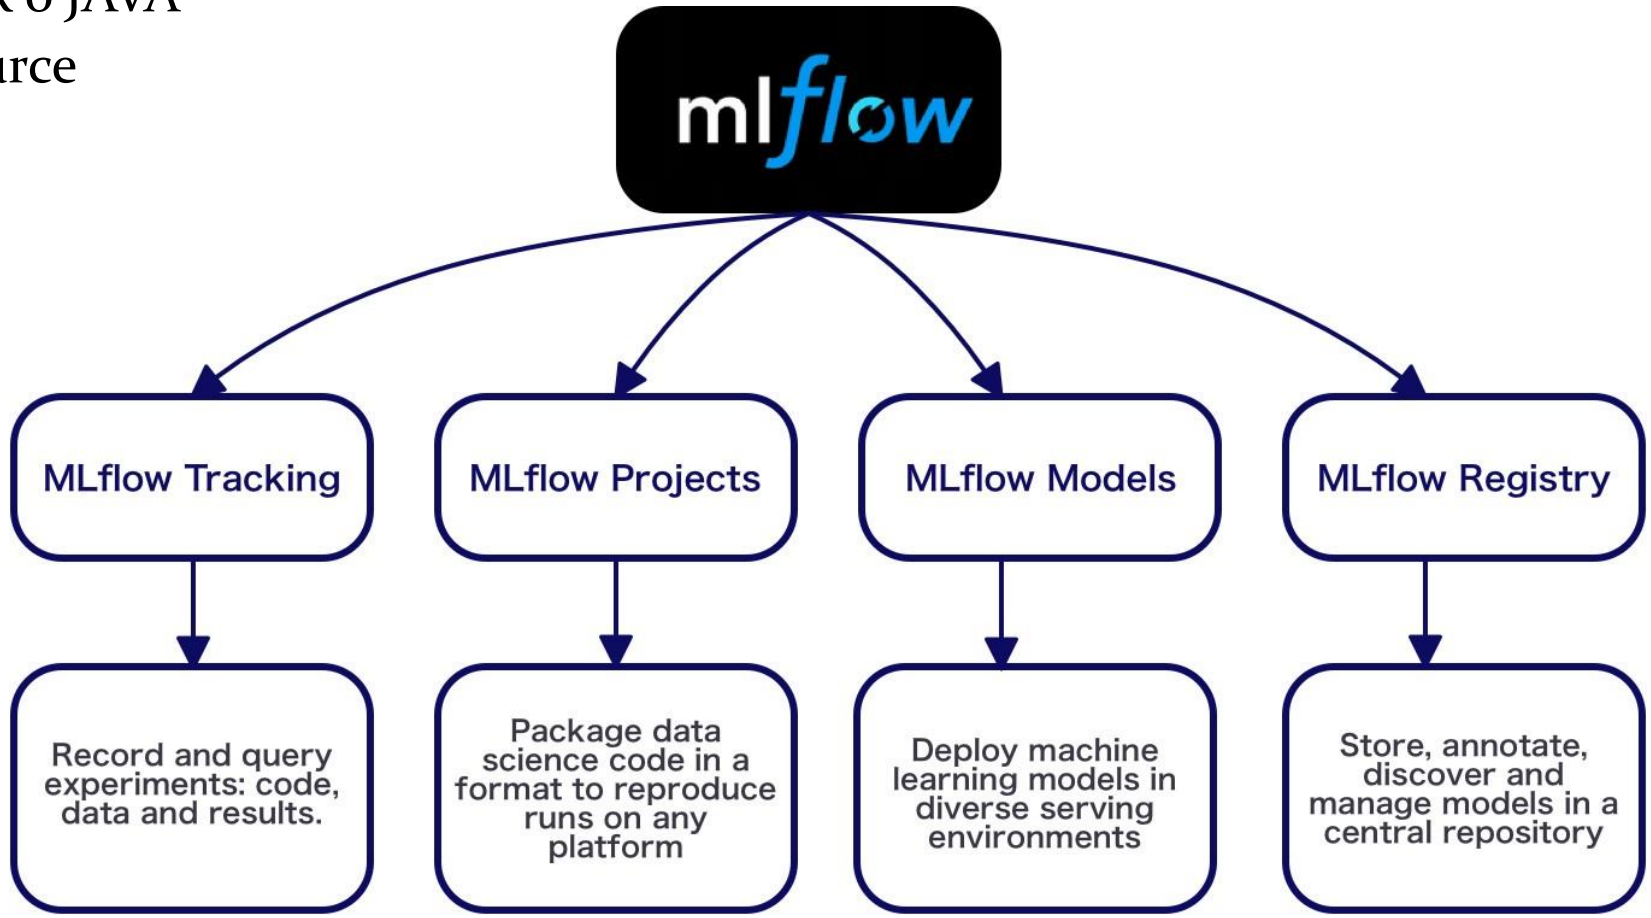

mlflow

- Esta herramienta facilita la gestión del ciclo de vida de los modelos
  - Se **almacena cada paso** durante la **fase de desarrollo** (metadata store)
  - Se **registran** todos los **modelos** (model registry)
  - **Mapeo** prueba -> modelo
  - Facilita el **despliegue**
  - **Reproducibilidad**

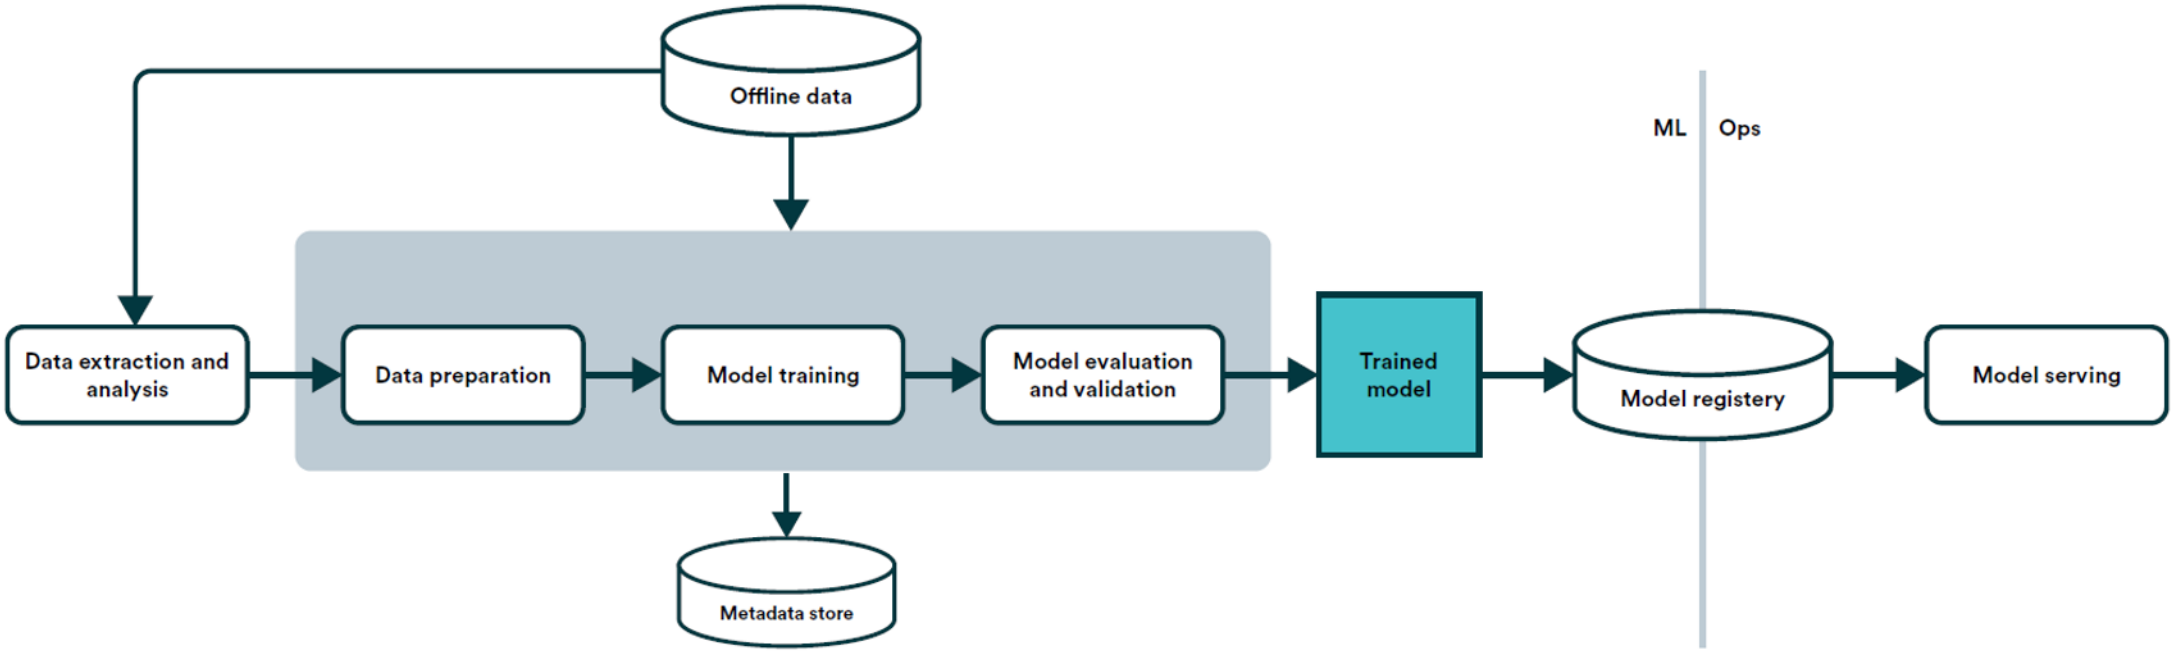

mlflow

- Mlflow dispone de un servidor para hacer el tracking
  - Los usuarios se pueden **conectar** de forma **remota al servidor**
  - Es **necesario** tener instalado **Mlflow** en el lado **cliente**
  - Los **metadatos** y **modelos** se **guardan** en el **servidor**

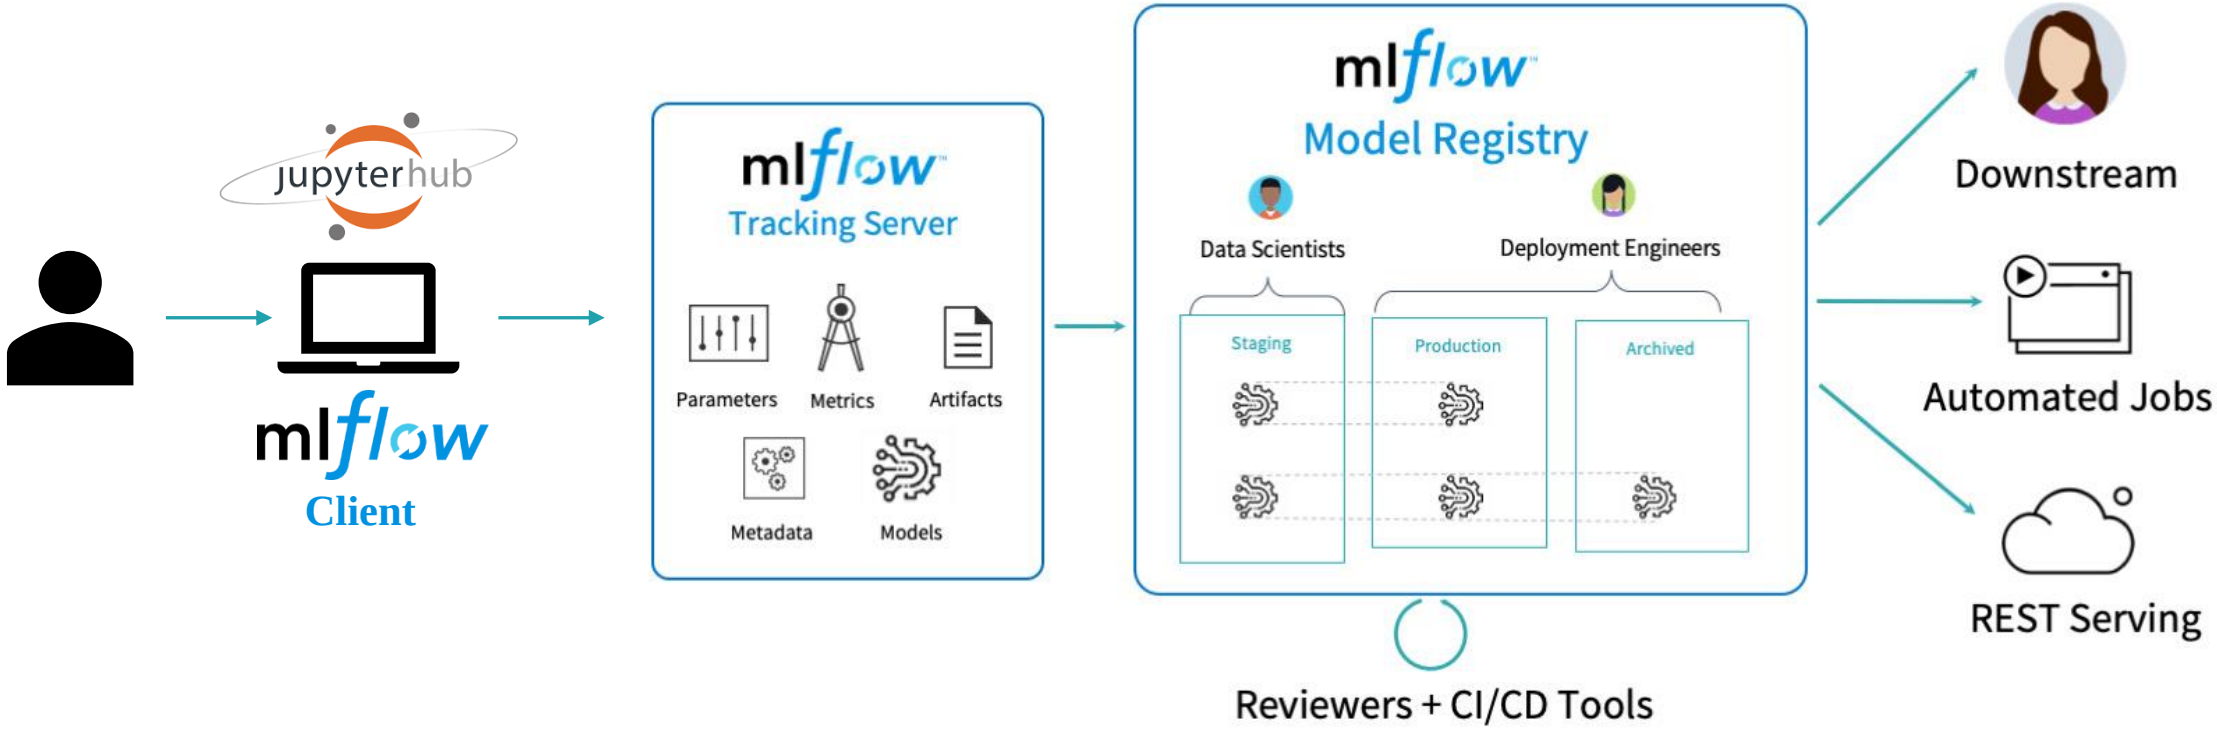

- MLflow tiene **integración** con **múltiples BBDD** y **repositorios**

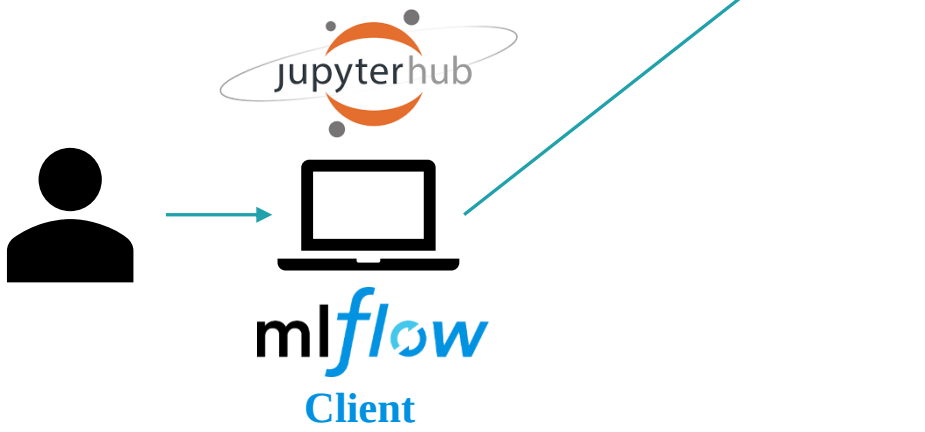

- Fichero local
- SQLite
- MySQL
- MSSQL
- PostgreSQL

mlflow

- MLflow tiene **integración** con **múltiples BBDD** y **repositorios**

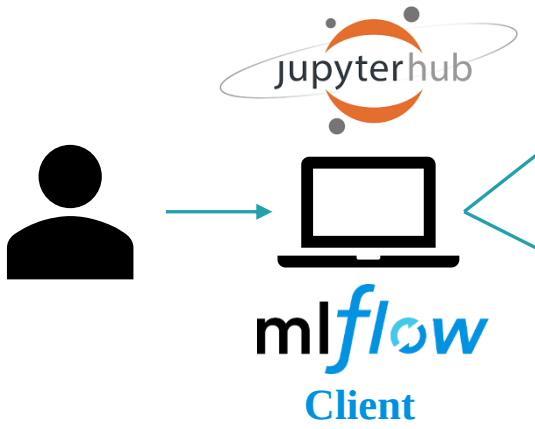

mlflow Tracking Server

- Fichero local
- SQLite
- MySQL
- MSSQL
- PostgreSQL

mlflow Model Registry

- Amazon S3
- Azure Blob Storage
- Google Cloud Storage
- Servidor FTP o SFTP
- NFS
- HDFS

mlflow - Tracking

- Estructura:
  - ***Experimento***: se refiere a un **proyecto común** que engloba las pruebas realizadas para generar un modelo para un caso de uso específico

```
mlflow.create_experiment(name, artifact_location=None)  [source]
```

    - ***RUN***: se refiere a una prueba o ejecución de entrenamiento que se realizan dentro de un experimento.

      - ***Parámetros***: hiperparámetros del modelo. Cada RUN tiene uno o varios parámetros asociados, pero para una ejecución en concreto cada parámetro solo puede tener un valor.

      - ***Métricas***: métricas de evaluación del modelo. Cada RUN tiene una o varias métricas asociadas, pero para una ejecución en concreto cada métrica solo puede tener un valor.

```
with mlflow.start_run():
    mlflow.log_param("x", 1)
    mlflow.log_metric("y", 2)
    ...
```

mlflow - Tracking

- Registra todos los metadatos de la prueba
- Cada prueba se organiza bajo el concepto ***RUN:***
  - **Code version**: versión del código (si está en un repositorio Git se registra el hash del commit).
  - **Start & end time**: cuándo se ha iniciado y finalizado el run.
  - **Source**: nombre del fichero donde se encuentra el código fuente o el nombre del proyecto.
  - **Parameters**: registra en formato clave/valor los parámetros utilizados para entrenar el modelo.
  - **Metrics**: registra en formato clave/valor las métricas definidas para evaluar el rendimiento.
  - **Artifacts**: registra el modelo entrenado en el formato especificado (artifact = modelo)

Client

mlflow - Tracking

- Registra todos los metadatos de la prueba
- Cada prueba se organiza bajo el concepto ***RUN:***
  - **Code version**: versión del código (si está en un repositorio Git se registra el hash del commit).
  - **Start & end time**: cuándo se ha iniciado y finalizado el run.
  - **Source**: nombre del fichero donde se encuentra el código fuente o el nombre del proyecto.
  - **Parameters**: registra en formato clave/valor los parámetros utilizados para entrenar el modelo.
  - **Metrics**: registra en formato clave/valor las métricas definidas para evaluar el rendimiento.
  - **Artifacts**: registra el modelo entrenado en el formato especificado (artifact = modelo)

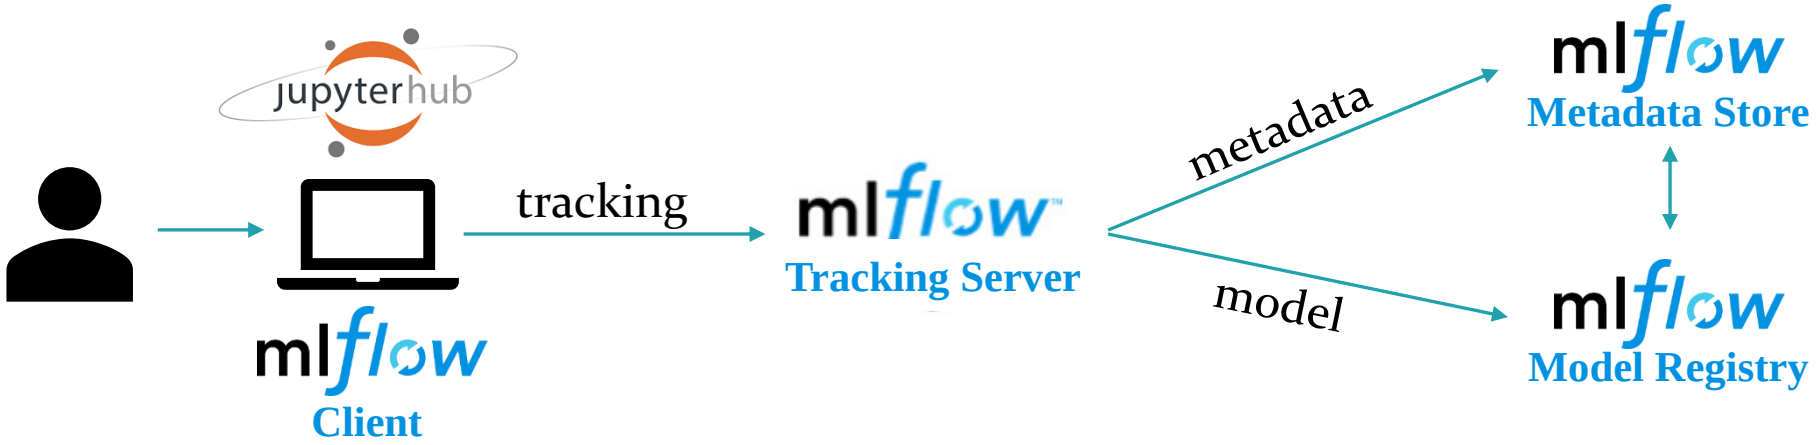

mlflow - Tracking

- Registra todos los metadatos de la prueba
- Cada prueba se organiza bajo el concepto ***RUN:***
  - metadata
    - **Code version**: versión del código (si está en un repositorio Git se registra el hash del commit).
    - **Start & end time**: cuándo se ha iniciado y finalizado el run.
    - **Source**: nombre del fichero donde se encuentra el código fuente o el nombre del proyecto.
    - **Parameters**: registra en formato clave/valor los parámetros utilizados para entrenar el modelo.
    - **Metrics**: registra en formato clave/valor las métricas definidas para evaluar el rendimiento.
  - model
    - **Artifacts**: registra el modelo entrenado en el formato especificado (artifact = modelo)

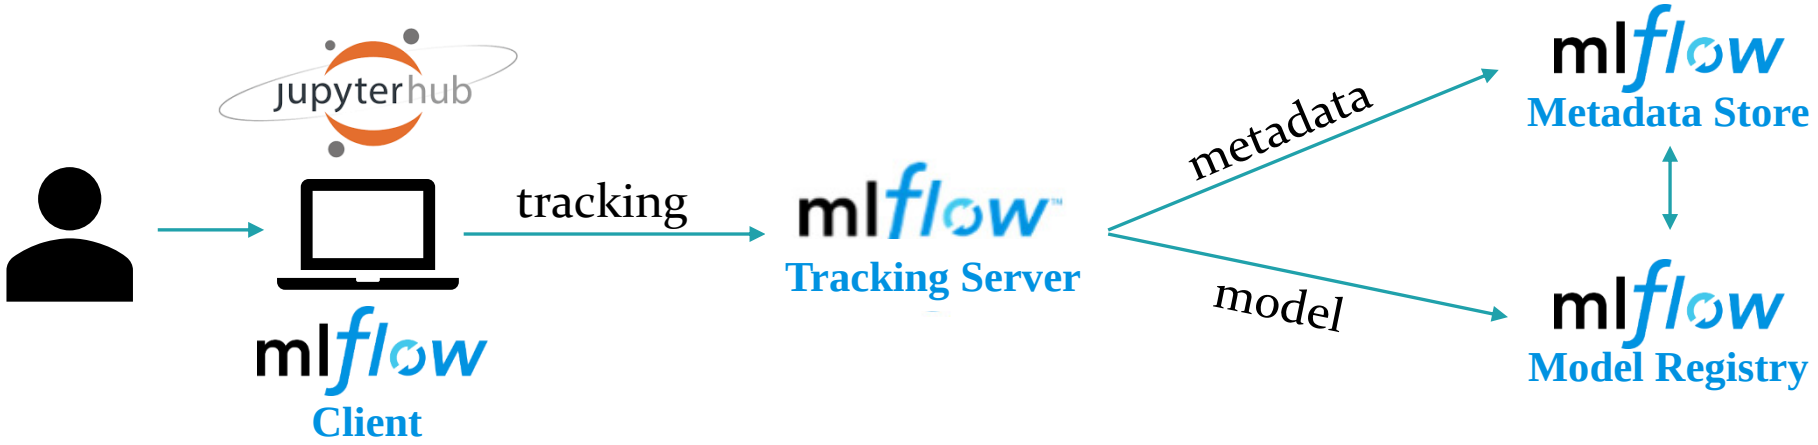

mlflow - Tracking

- Interfaz gráfica (http://<ip-servidor>:5000)

					Parameters		Metrics		
	Date ▼	User	Source	Version	alpha	lambda	mae	r2	rmse
	2018-08-30 15:42:55	mlflow	R:train.R	da3f0a	1	1	0.638	0.03	0.857
	2018-08-30 15:42:50	mlflow	R:train.R	da3f0a	1	0.5	0.639	0.039	0.853
	2018-08-30 15:42:45	mlflow	R:train.R	da3f0a	1	0.2	0.617	0.153	0.804
	2018-08-30 15:42:40	mlflow	R:train.R	da3f0a	1	0	0.597	0.224	0.77
	2018-08-30 15:42:35	mlflow	R:train.R	da3f0a	0.5	1	0.639	0.039	0.853
	2018-08-30 15:42:30	mlflow	R:train.R	da3f0a	0.5	0.5	0.621	0.125	0.818
	2018-08-30 15:42:26	mlflow	R:train.R	da3f0a	0.5	0.2	0.616	0.169	0.794
	2018-08-30 15:42:21	mlflow	R:train.R	da3f0a	0.5	0	0.597	0.224	0.77
	2018-08-30 15:42:15	mlflow	R:train.R	da3f0a	0	1	0.617	0.158	0.801
	2018-08-30 15:42:09	mlflow	R:train.R	da3f0a	0	0.5	0.617	0.171	0.793
	2018-08-30 15:42:04	mlflow	R:train.R	da3f0a	0	0.2	0.618	0.178	0.788
	2018-08-30 15:41:50	mlflow	R:train.R	da3f0a	0	0	0.597	0.224	0.77

mlflow - Model Registry

- Registra los modelos de cada prueba
- Cada prueba se organiza bajo el concepto ***RUN:***
  - **Model**: modelo generado a partir de un experimento o run
  - **Registered modelo**: modelo registrado con un identificador único que tiene asociado la versión, el estado, la trazabilidad y otros metadatos
  - **Model version**: versión del modelo. Versión incremental automática
  - **Model Stage**: el estado del modelo (staging, production, archived, etc.)
  - **Annotation & description**: notas opcionales en formato Markdown

mlflow - Project

- Empaqueta el proyecto en un formato reproducible en cualquier plataforma
  - Incluye dependencias de librerías
  - Incluye el código
  - Define los parámetros de entrada (opcional)

- *Un **proyecto MLflow** contiene lo siguiente (MLproject file):*
  - **Name**: nombre del proyecto
  - **Environment**: entorno de ejecución
    - **Conda**: entorno de ejecución generado con Conda (*conda.yaml*)
    - **Docker**: entorno de ejecución generado mediante Docker (*Dokerfile*)
  - **Entry point**: punto de entrada del proyecto o comandos para ejecutar el proyecto
    - Puede tener varios puntos de entrada
    - Puede ser un ***.py*** o un ***.sh***

mlflow - Project

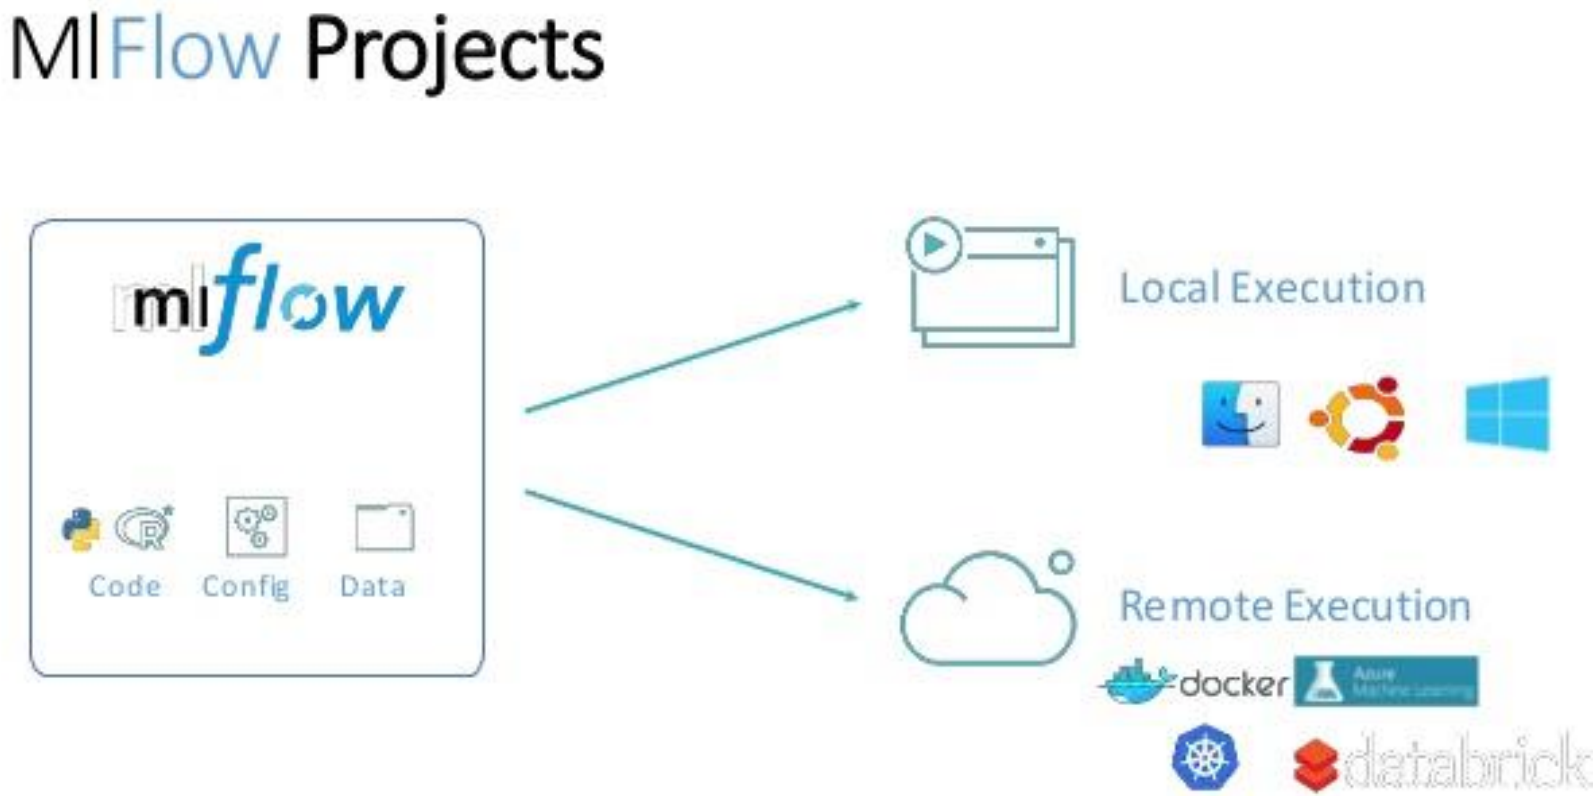

mlflow - Project

- Ejemplo

```
name: My Project

conda_env: my_env.yaml
# Can have a docker_env instead of a conda_env, e.g.
# docker_env:
#    image:  mlflow-docker-example

entry_points:
  main:
    parameters:
      data_file: path
      regularization: {type: float, default: 0.1}
    command: "python train.py -r {regularization} {data_file}"
  validate:
    parameters:
      data_file: path
    command: "python validate.py {data_file}"
```

mlflow - Model

- Guarda el modelo en un formato estándar y es capaz de servirlo

- Cada MLflow Model es un directorio que contiene ficheros arbitrarios junto con un fichero llamado ***MLmodel***

```
# Directory written by mlflow.sklearn.save_model(model, "my_model")
my_model/
├── MLmodel
└── model.pkl
```

- El fichero MLmodel contiene los flavors (formatos) en los que se puede ejecutar el modelo (soporte)

```
time_created: 2018-05-25T17:28:53.35

flavors:
  sklearn:
    sklearn_version: 0.19.1
    pickled_model: model.pkl
  python_function:
    loader_module: mlflow.sklearn
```

mlflow - Model

- ¿Qué es un **flavor**?
  - Es una **convención** para que las herramientas de despliegue **entiendan cómo pueden usar el modelo**

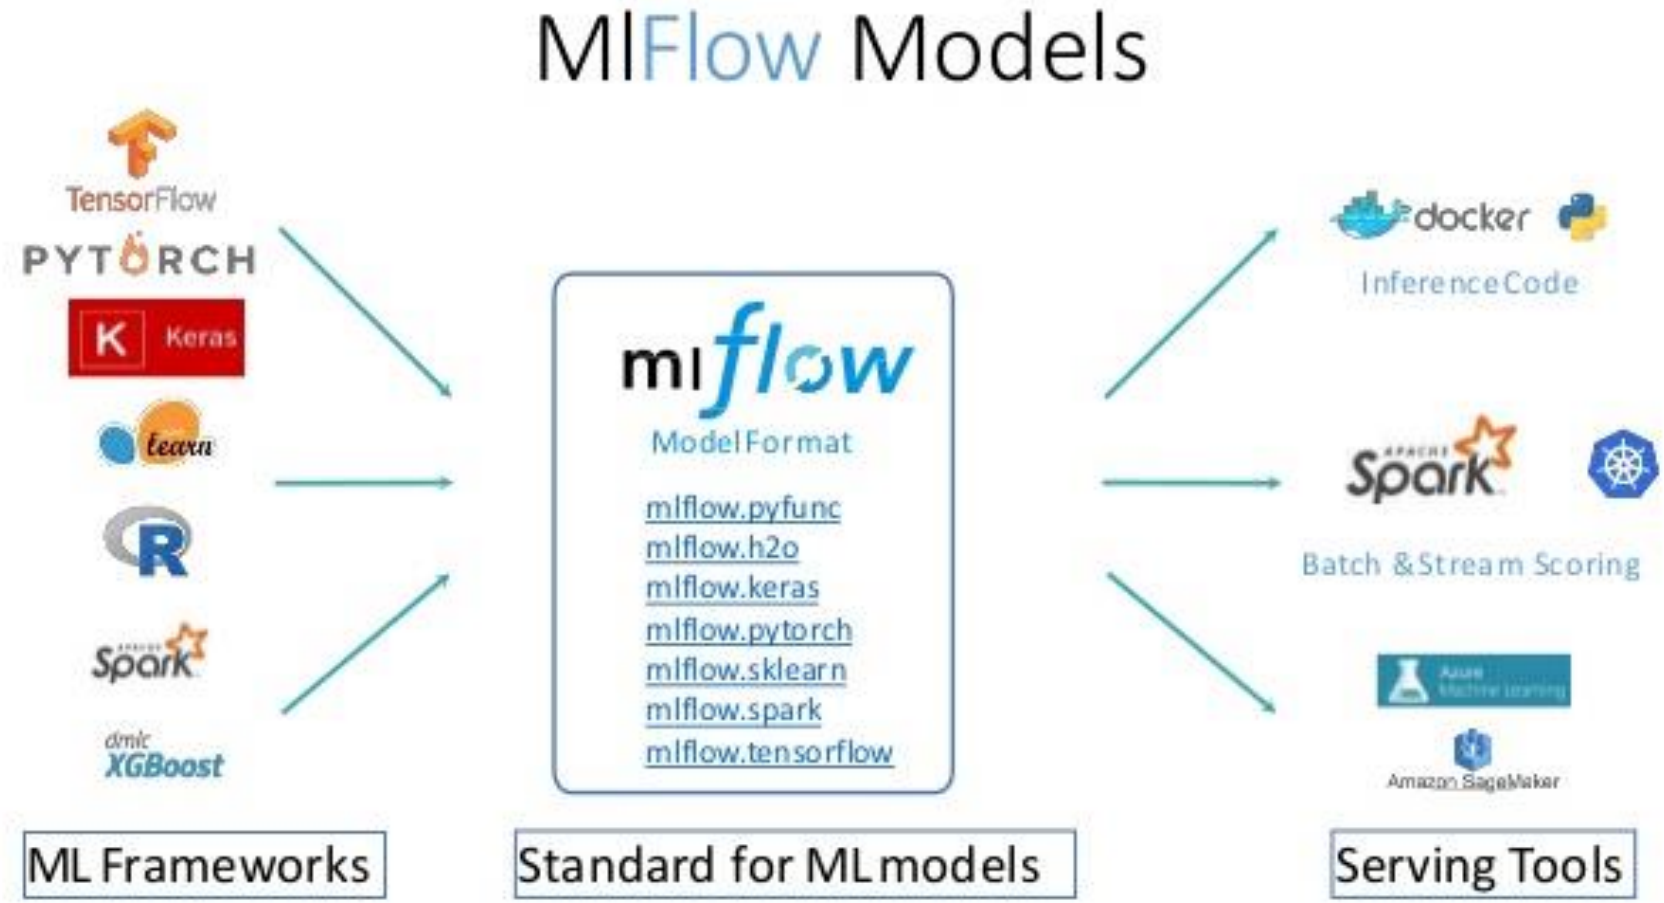

mlflow - Model

- **Model Signature**
  - Define el **esquema** de los **parámetros** de **entrada** y de **salida** del modelo
    - Nombre
    - Tipos de datos

  - **Fuerza** que el modelo se ejecute con el **esquema** definido
    - **Genera excepciones** si las **variables** de entrada **no** son las **correctas**
    - O el **orden** de las variables **no es el correcto**

```
signature:
    inputs: '[{"name": "sepal length (cm)", "type": "double"}, {"name": "sepal width
      (cm)", "type": "double"}, {"name": "petal length (cm)", "type": "double"}, {"name":
      "petal width (cm)", "type": "double"}]'
    outputs: '[{"type": "integer"}]'
```

¿Demasiada información?

Resumen

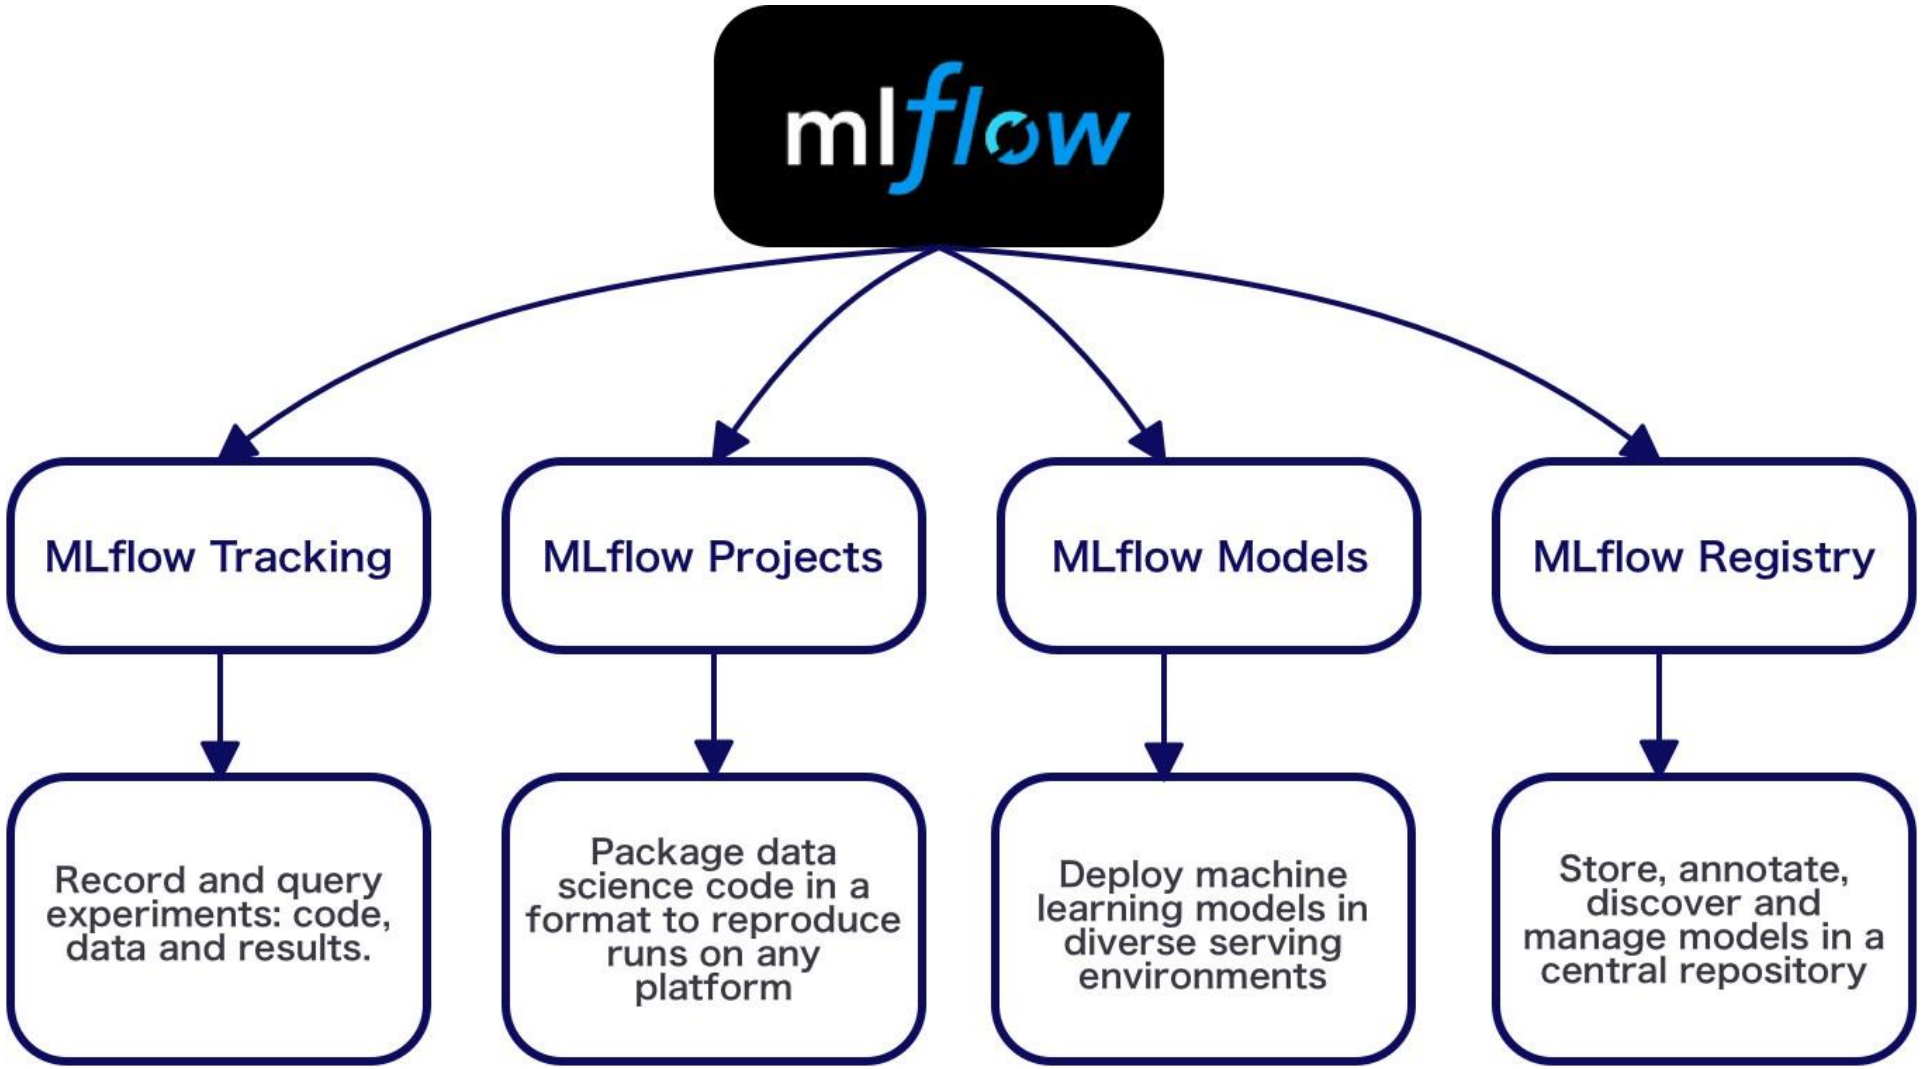
mlflow
MLflow Tracking
MLflow Projects
MLflow Models
MLflow Registry
Record and query experiments: code, data and results.
Package data science code in a format to reproduce runs on any platform
Deploy machine learning models in diverse serving environments
Store, annotate, discover and manage models in a central repository

¿Aún así podemos mejorar?

¿Cómo automatizar esto?

Pipelines automatizados